

AI SCIENTIST

FASE 2

DATA PREPARE

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

FASE 2

Olá, cientista!

Etapa do entendimento de negócio concluída com sucesso! Agora, seguindo a metodologia do CRISP DM, entramos na etapa da **preparação dos dados**. Se a Fase 1 te ajudou a pensar como cientista de dados, essa fase vai te ensinar a operar dados no mundo real.

Aqui começa a transição mais importante da formação: sair do cenário idealizado de datasets prontos e limpos e entrar no território onde os dados são grandes, distribuídos, inconsistentes, caros e, muitas vezes, caóticos. É exatamente por isso que essa fase existe.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

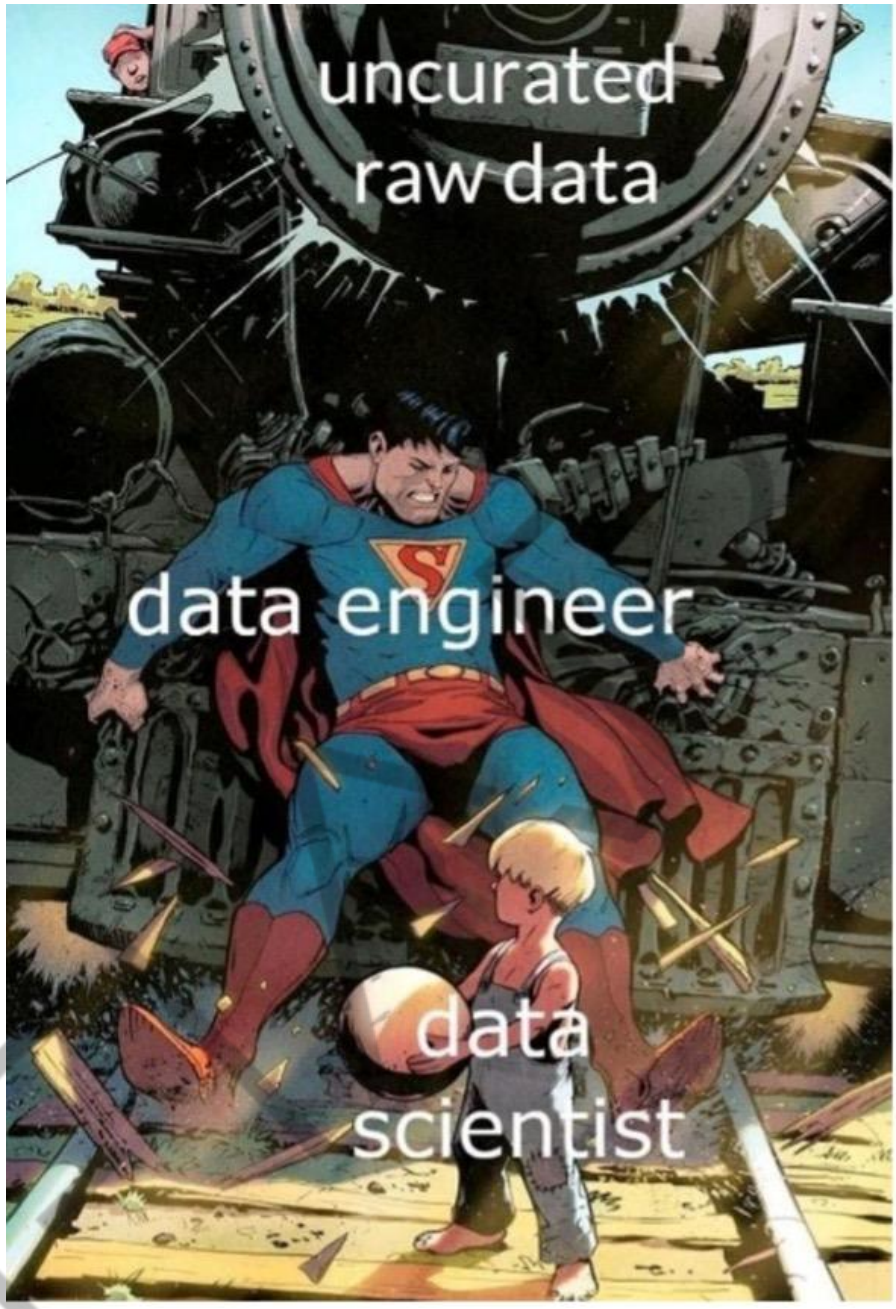


Figura 1 - Relação engenharia de dados com ciência de dados.
Fonte: https://www.i2ai.org/content/blog/2021/6/engenharia-de-dados-para-todos/

Por que um(a) cientista de dados precisa aprender tudo isso?

Porque, na prática, você terá muitos outros desafios na sua carreira de cientista de dados, além de modelagem preditiva, tal como a **preparação dos dados**. Na maior parte dos projetos reais, o modelo é apenas a ponta do iceberg. Antes dele existir, alguém precisava entender de onde os dados vêm, como são gerados, quais regras de negócio os impactam, quais problemas de qualidade eles carregam e como tudo isso pode ser organizado de forma confiável e escalável.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Além disso, os dados raramente chegam prontos para uso. Eles estão espalhados em diferentes sistemas, formatos e tecnologias, exigindo que a pessoa cientista de dados saiba consultar, integrar, transformar e validar informações de maneira eficiente. Isso envolve dominar bancos de dados relacionais, compreender quando e por que usar soluções NoSQL, lidar com grandes volumes de dados e trabalhar com processamento distribuído.

Outro ponto fundamental é a escala. Soluções que funcionam em um notebook local muitas vezes não sobrevivem quando aplicadas a ambientes corporativos, com milhões de registros, dados em tempo real e restrições de custo. Entender arquitetura de dados, pipelines de ETL/ELT e ambientes de Cloud permite que você construa soluções que não apenas funcionam, mas que funcionam de forma sustentável ao longo do tempo.

Nessa fase, você vai aprender disciplinas como:

Arquitetura de Big Data: você aprende a pensar estrategicamente sobre onde os dados devem viver, como eles chegam até você e como escalam ao longo do tempo. Entender Data Lake, Data Warehouse e conceitos como Data Mesh te tira da posição de “consumidor passivo” de dados e te coloca como alguém capaz de dialogar com engenheiros, arquitetos e times de negócio. Spark e processamento distribuído entram exatamente aqui: quando os dados não cabem mais em uma máquina, você precisa saber como pensar distribuído.

Banco de dados relacionais para cientistas de dados: Já os bancos de dados relacionais seguem sendo uma das ferramentas mais importantes da área. SQL avançado, agregações, subqueries, índices e partições não são apenas detalhes técnicos, são o que separa uma análise lenta e frágil de uma análise eficiente e confiável. Um cientista de dados que domina SQL consegue explorar hipóteses mais rápido, validar ideias com agilidade e entender profundamente a estrutura dos dados com os quais trabalha.

NoSQL para ciência de dados: Quando avançamos para NoSQL, o jogo muda. Aqui você aprende que nem todo dado cabe em tabelas. Modelos chave-valor, documentos, colunas e grafos ampliam seu repertório para lidar com logs, eventos, dados semi-estruturados e aplicações modernas. A introdução aos bancos vetoriais conecta diretamente essa fase com machine learning, IA generativa e

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

sistemas de recomendação, mostrando como a forma de armazenar dados influencia diretamente o tipo de solução que você consegue construir.

ETL Pipelines: Os pipelines de ETL/ELT são, talvez, o ponto mais crítico dessa fase. Eles representam a ponte entre o dado bruto e o dado pronto para análise. Aqui você aprende a integrar múltiplas fontes, lidar com dados em tempo real, trabalhar com ferramentas como Kafka e operar em ambientes de Cloud. Mais do que isso: você passa a entender o custo da decisão técnica, explorando conceitos de FinOps para equilibrar performance, escalabilidade e orçamento (algo cada vez mais valorizado no mercado).

Dentro do CRISP-DM, essa fase sustenta diretamente as etapas de **Data Understanding** e **Data Preparation**, que são a base de todo o ciclo analítico. É aqui que você:

- Entende a origem dos dados,
- Avalia sua qualidade,
- Identifica limitações,
- Realiza transformações,
- Integra diferentes fontes,
- Prepara o terreno para a modelagem.

Sem essa base sólida, a fase de Modeling vira tentativa e erro, a Evaluation perde confiabilidade e o Deployment se torna frágil ou inviável. Em outras palavras: dados mal preparados comprometem todo o projeto, independentemente do quão sofisticado seja o algoritmo.

Aproveite para perguntar, explorar, errar e entender profundamente o “por trás” dos dados. É esse conhecimento que vai sustentar tudo o que vem depois. Espero que você aproveite muito essa jornada e aprenda mais sobre o mundo da engenharia de dados nessa fase tão importante.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com