

AI SCIENTIST

FASE 2 | AULA 01 -

ARQUITETURA DE DADOS: DATA LAKE VS DATA WAREHOUSE

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SUMÁRIO

O QUE VEM POR AÍ? 3
HANDS ON 4
SAIBA MAIS 5
MERCADO, CASES E TENDÊNCIAS 21
O QUE VOCÊ VIU NESTA AULA? 23
REFERÊNCIAS 24

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VEM POR AÍ?

Quando abordamos arquitetura de dados, inevitavelmente falamos de decisões que impactam diretamente a forma como uma organização gera valor a partir da informação. Muito antes do Big Data, dois grandes pensadores moldaram a forma como empresas organizam seus dados analíticos: **Ralph Kimball** e **Bill Inmon**. Suas abordagens, embora diferentes, seguem influenciando arquiteturas modernas até hoje.

Neste material, você vai entender quem são Kimball e Inmon, quais são suas modelagens, as diferenças conceituais entre elas e como essas ideias evoluíram até o surgimento do **Data Lake**. Além disso, veremos na prática como essas arquiteturas convivem no mundo real, implementando um **Data Warehouse** e um **Data Lake** utilizando o **Databricks**, uma das plataformas mais adotadas atualmente em ambientes de Big Data.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

HANDS ON

Data Warehouse E Data Lake No Databricks

Este hands on transforma conceitos arquiteturais em prática real. Você irá implementar duas arquiteturas no mesmo ambiente: primeiro um Data Warehouse tradicional, depois um Data Lake em camadas, evidenciando diferenças de modelagem, ingestão e consumo de dados.

A ideia central é mostrar que Data Warehouse e Data Lake não competem — eles se complementam dentro de uma arquitetura moderna (Lakehouse). Todo o cenário será construído no Databricks, simulando um ambiente corporativo completo: criação do workspace, ingestão de dados, transformação, modelagem e consumo analítico.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SAIBA MAIS

Introdução ao Databricks

O Databricks é uma plataforma unificada de dados e analytics criada pelos próprios autores do Apache Spark, e projetada para simplificar o trabalho com engenharia de dados, analytics, ciência de dados e Machine Learning em um único ambiente colaborativo. Ele abstrai grande parte da complexidade de infraestrutura, permitindo que times foquem na arquitetura, nos dados e no valor de negócio.

Na prática, o Databricks viabiliza o conceito de Lakehouse, combinando o melhor dos dois mundos: a governança, performance e confiabilidade dos Data Warehouses com a flexibilidade e escalabilidade dos Data Lakes

Tudo isso usando **notebooks, SQL, jobs, clusters elásticos** e armazenamento desacoplado, o que o torna ideal para simular **cenários corporativos reais**, como faremos neste hands on.

Por que Databricks neste tutorial?

Porque ele permite implementar, **no mesmo ambiente**, tanto um **Data Warehouse tradicional** quanto um **Data Lake em camadas**, evidenciando diferenças de abordagem **sem trocar de ferramenta** — exatamente como acontece em arquiteturas modernas de dados.

Para o hands on (na seção anterior), utilizaremos o **Databricks Community Edition**, uma versão **gratuita** da plataforma, ideal para **estudos, provas de conceito e aprendizado prático**. Apesar de ter limitações de escala e recursos corporativos, ela mantém os **principais conceitos e ferramentas** da plataforma: notebooks, Spark, SQL e armazenamento de dados, sendo perfeita para experimentar arquiteturas de **Data Warehouse** e **Data Lake**.

Por que usar o Databricks Community?

- Não exige cartão de crédito.
- Ambiente pronto para uso em minutos.
- Suporte a SQL, Python e Spark.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- Ideal para aulas, laboratórios e estudos individuais.

Tudo o que será construído aqui reflete práticas reais de mercado — apenas adaptadas ao contexto educacional da Community Edition.

Parte 0 – Acessando o Databricks Community Edition

Criar sua conta:

1. Acesse o site.
2. Crie uma conta gratuita ou faça login.
3. Após o login, você será direcionado automaticamente para o **Workspace**.

No Community Edition, o cluster já vem pré-configurado e iniciado.

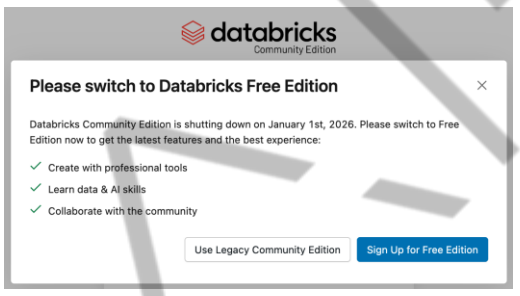


Figura 1 – Criando conta
Fonte: Databricks (2026)

Escolha a opção “Sign Up for Free Edition” e a forma de fazer o login.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



Figura 2 – Inscrição
Fonte: Databricks (2026)

Entendendo o Ambiente

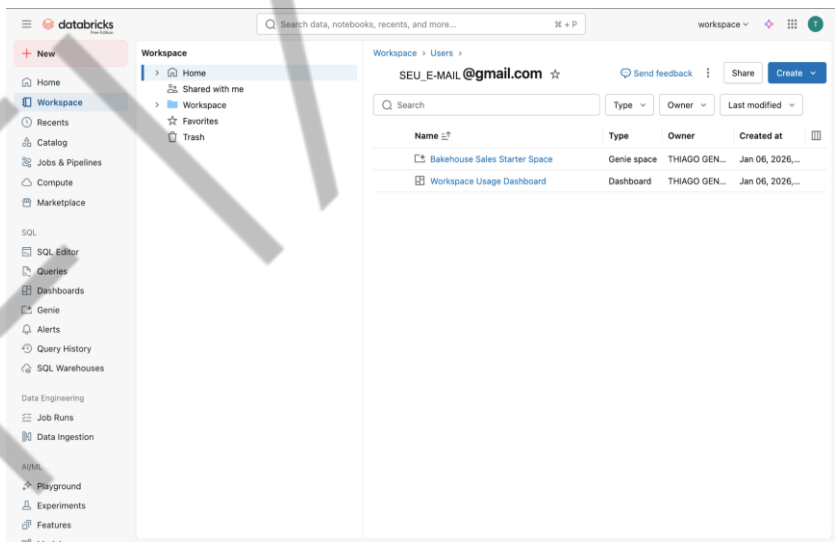


Figura 3 – Ambiente
Fonte: Databricks (2026)

Menu lateral esquerdo

- **Home** → Visão geral.
- **Workspace** → Onde você cria notebooks e organiza pastas (**é aqui que vamos trabalhar**).

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- **Catalog** → Metadados e tabelas.
- **Compute** → (limitado no Free Edition, já vem pronto).
- **SQL Editor** → Consultas SQL.
- **Dashboards** → Visualização analítica.
- **Jobs & Pipelines** → Execuções (não usaremos aqui).

Importante:
No Free Edition, não é necessário criar cluster manualmente — o ambiente já está pronto para executar notebooks.

ETAPA 0 – Criar o Volume (Storage)

Criar Volume no Catalog

1. No menu esquerdo, clique em **Catalog.**
2. Selecione:
   - **Catalog:** `workspace;`
   - **Schema:** `default.`
3. Clique em Create → Volume.
4. Configure:
   - **Name:** tutorial_fiap;

     Type: Managed.
5. Clique em **Create.**

Isso cria o caminho físico: /Volumes/workspace/default/tutorial_fiap/

Upload do arquivo CSV para o Volume

Ainda em **Catalog:**

- Navegue até: workspace → default → tutorial_fiap.
- Clique em **Upload e** faça upload do arquivo: vendas.csv.
- Confirme que o arquivo aparece em: Volumes/workspace/default/tutorial_fiap/vendas.csv.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Upload do arquivo CSV para o Volume

Ainda em Catalog:

- Navegue até: workspace → default → tutorial_fiap.
- Clique em Upload e faça upload do arquivo: vendas.csv.

Confirme que o arquivo aparece em: `/Volumes/workspace/default/tutorial_fiap/vendas.csv`.

ETAPA 1 – Criar os Notebooks

Criar Notebook SQL – Data Warehouse:

- Clique em **Workspace.**
- Clique em Create ▾ → Notebook.
- Configure:
  - **Name:** 01_dw_hands_on;
  - **Language:** SQL;
  - **Location:** seu usuário.

Criar Notebook SQL – Data Lake

- Clique em **Workspace.**
- Clique em Create ▾ → Notebook.
- Configure:
  - **Name:** 02_dl_hands_on.
  - Language: SQL.

Usaremos **somente SQL** neste hands on para reforçar o foco arquitetural.

PARTE 1 – Data Warehouse (Notebook 01_dw_hands_on)

Criar Database de Staging: `CREATE DATABASE IF NOT EXISTS dw_staging;`

Criar Tabela Staging (CTAS + `read_files()`).

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

```
CREATE TABLE dw_staging.vendas_raw
AS
SELECT
  CAST(id_venda AS INT)       AS id_venda,
  CAST(id_cliente AS INT)     AS id_cliente,
  CAST(id_produto AS INT)     AS id_produto,
  CAST(data_venda AS DATE)    AS data_venda,
  CAST(quantidade AS INT)     AS quantidade,
  CAST(valor_total AS DOUBLE) AS valor_total
FROM read_files(
  '/Volumes/workspace/default/tutorial_fiap/vendas.csv',
  format => 'csv',
  header => 'true'
);
```

Código-fonte 1 – SQL
Fonte: elaborado pelo autor (2026)

Criar Database Analítico: `CREATE DATABASE IF NOT EXISTS dw;`

Modelagem Dimensional

Dimensão Cliente:

```
CREATE TABLE dw.dim_cliente AS
SELECT DISTINCT
  id_cliente,
  CONCAT('Cliente ', id_cliente) AS nome_cliente
FROM dw_staging.vendas_raw;
```

Código-fonte 2 – SQL
Fonte: elaborado pelo autor (2026)

Dimensão Produto

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

```
CREATE TABLE dw.dim_produto AS
SELECT DISTINCT
  id_produto,
  CONCAT('Produto ', id_produto) AS nome_produto
FROM dw_staging.vendas_raw;
```

Código-fonte 3 – SQL
Fonte: elaborado pelo autor (2026)

Fato Vendas

```
CREATE TABLE dw.fato_vendas AS
SELECT
  id_venda,
  id_cliente,
  id_produto,
  data_venda,
  quantidade,
  valor_total
FROM dw_staging.vendas_raw;
```

Código-fonte 4 – SQL
Fonte: elaborado pelo autor (2026)

Consulta Analítica

```
SELECT
  p.nome_produto,
  SUM(f.valor_total) AS faturamento
FROM dw.fato_vendas f
JOIN dw.dim_produto p
  ON f.id_produto = p.id_produto
GROUP BY p.nome_produto;
```

Código-fonte 5 – SQL
Fonte: elaborado pelo autor (2026)

PARTE 2 – Data Lake (Notebook `02_dl_hands_on`)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Criar Database do Data Lake: `CREATE DATABASE IF NOT EXISTS datalake.`

Camada RAW

```
CREATE TABLE datalake.raw_vendas
AS
SELECT *
FROM read_files(
  '/Volumes/workspace/default/tutorial_fiap/vendas.csv',
  format => 'csv',
  header => 'true'
);
```

Código-fonte 6 – SQL
Fonte: elaborado pelo autor (2026)

Camada REFINED

```
CREATE TABLE datalake.refined_vendas
AS
SELECT
  CAST(id_venda AS INT)        AS id_venda,
  CAST(id_cliente AS INT)      AS id_cliente,
  CAST(id_produto AS INT)      AS id_produto,
  CAST(data_venda AS DATE)     AS data_venda,
  CAST(quantidade AS INT)      AS quantidade,
  CAST(valor_total AS DOUBLE) AS valor_total
FROM datalake.raw_vendas;
```

Código-fonte 7 – SQL
Fonte: elaborado pelo autor (2026)

Camada CURATED

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

```
CREATE TABLE datalake.curated_faturamento_produto
AS
SELECT
  id_produto,
  SUM(valor_total) AS faturamento_total
FROM datalake.refined_vendas
GROUP BY id_produto;
```

Código-fonte 8 – SQL
Fonte: elaborado pelo autor (2026)

Kimball e Inmon: quem são e por que são tão importantes?

Ralph Kimball é conhecido como o principal defensor da abordagem **bottom-up** para Data Warehousing. Sua proposta parte das áreas de negócio, criando Data Marts específicos que, juntos, formam o Data Warehouse corporativo. Sua principal contribuição é a **modelagem dimensional**, focada em simplicidade, performance e facilidade de uso para análise.

Bill Inmon, por outro lado, é considerado o “pai do Data Warehouse”. Ele defende uma abordagem **top-down**, onde primeiro se constrói um Data Warehouse corporativo centralizado, altamente normalizado, para depois derivar Data Marts específicos. Sua visão prioriza integração, consistência e governança desde a origem.

MODELAGEM KIMBALL – DIMENSIONAL

Star Schema

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

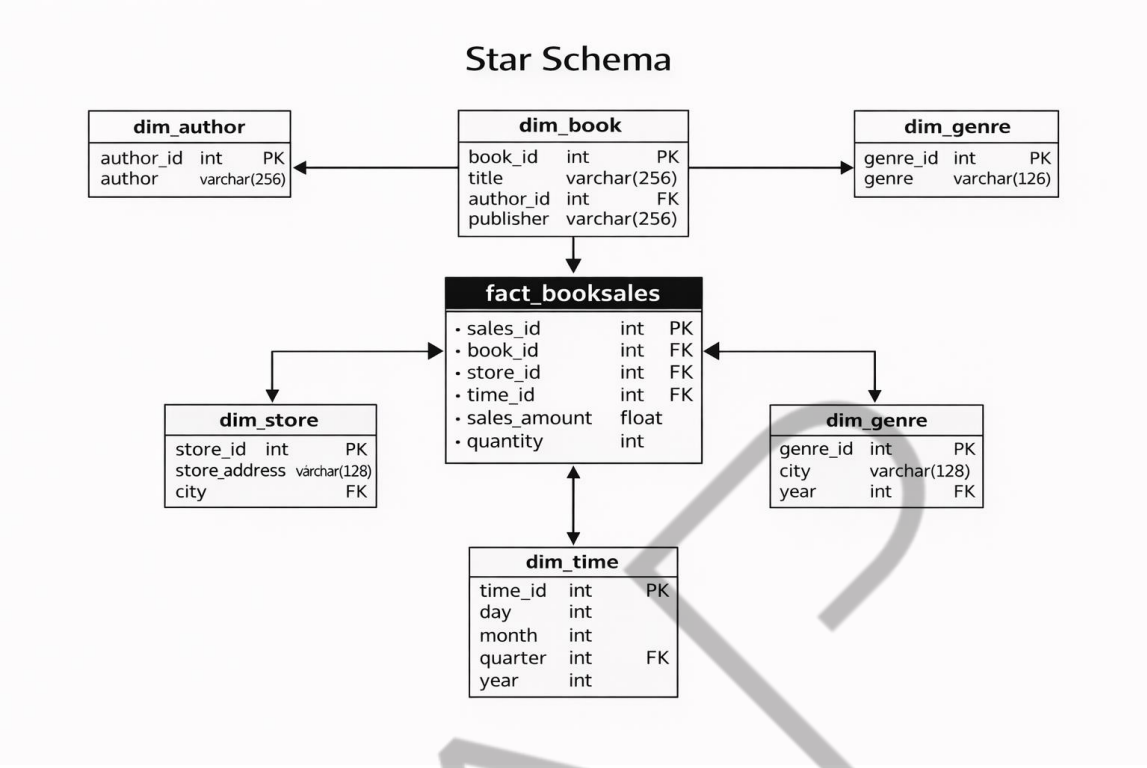


Figura 4 - Star Schema
Fonte: Elaborado pelo autor (2026)

Snowflake Schema

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

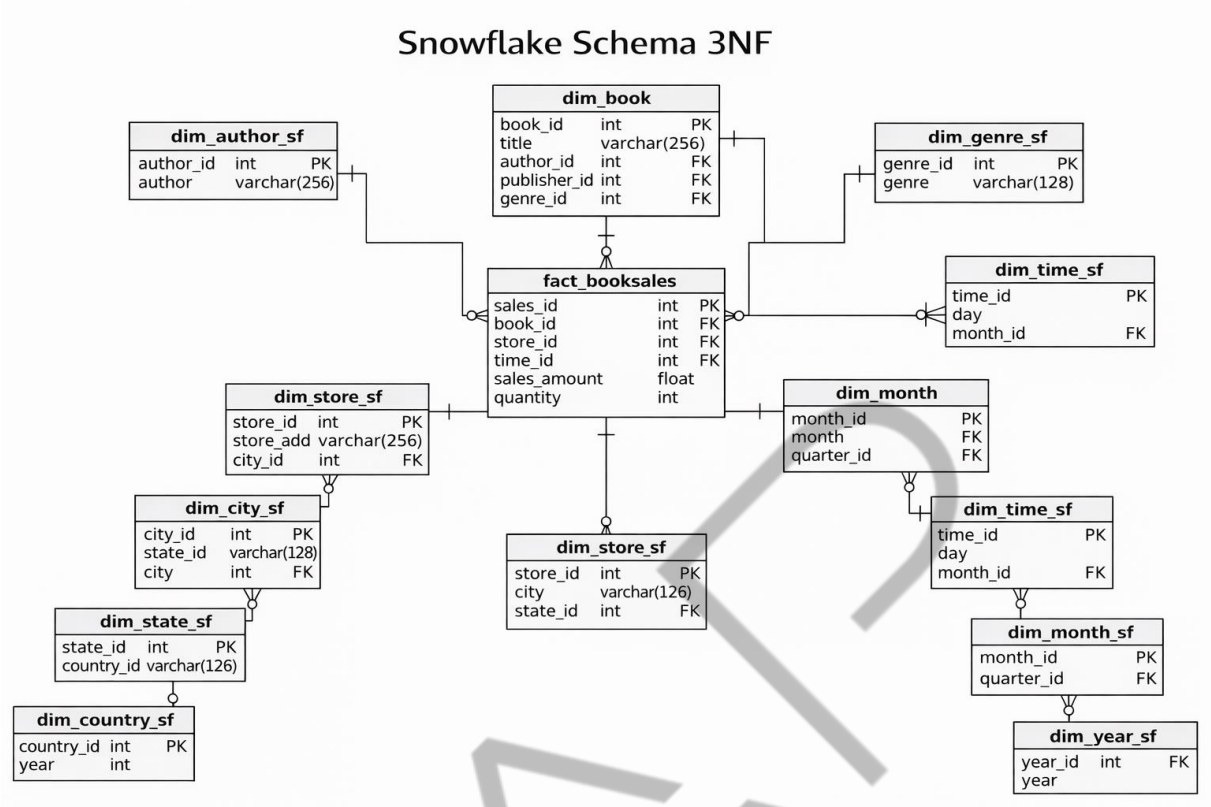


Figura 5 - Snowflake Schema
Fonte: Elaborado pelo autor (2026)

A modelagem de Kimball utiliza estruturas como **Star Schema** e **Snowflake Schema**, organizando os dados em:

- **Tabelas Fato**: métricas e eventos de negócio.

  Tabelas Dimensão: contexto descritivo (tempo, cliente, produto).

Essa abordagem é amplamente utilizada em ambientes analíticos por oferecer:

- Alta performance em consultas.
- Facilidade de entendimento pelo negócio.
- Forte aderência a ferramentas de BI.

Modelagem Inmon – Corporativa Normalizada

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

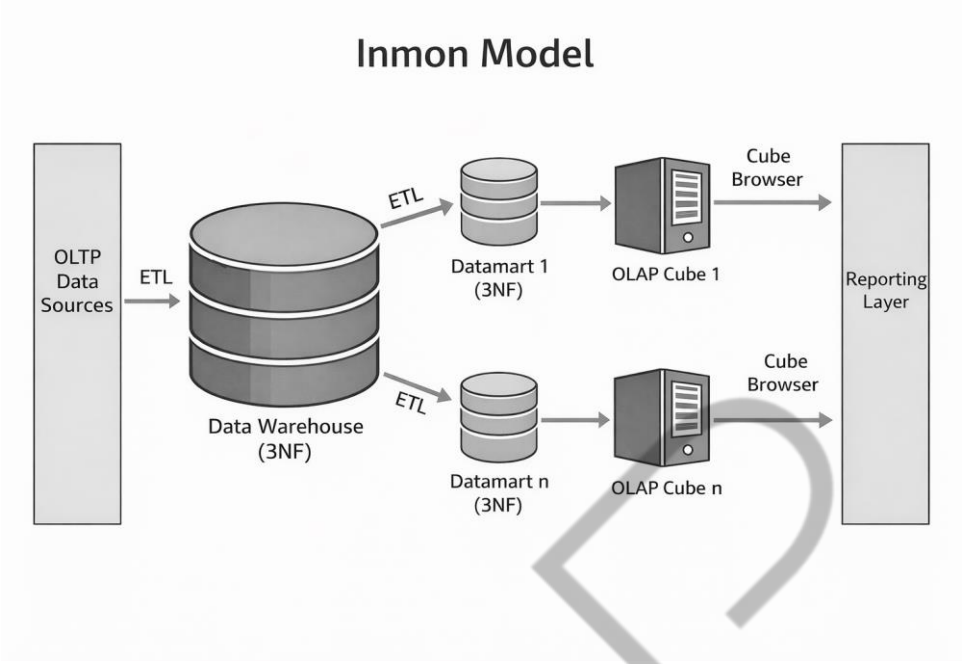


Figura 6 - Modelagem Inmon – Corporativa Normalizada
Fonte: Elaborado pelo autor (2026)

A proposta de Inmon é construir um Data Warehouse corporativo em **3ª forma normal**, altamente integrado, servindo como fonte única da verdade. A partir dele, os Data Marts são derivados conforme a necessidade das áreas de negócio.

Essa abordagem oferece:

- Alto nível de governança.
- Consistência semântica.
- Maior complexidade de implementação.
- Menor flexibilidade para mudanças rápidas.

COMO SURGIU O DATA LAKE?

Com o crescimento exponencial de dados não estruturados e semiestruturados, as arquiteturas tradicionais passaram a enfrentar limitações. Surgiu então o **Data Lake**, impulsionado por tecnologias como Hadoop e armazenamento em cloud.

O Data Lake nasceu para resolver três grandes desafios:

- Armazenar grandes volumes de dados a baixo custo.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- Suportar múltiplos formatos de dados.
- Permitir novos tipos de análise, como Machine Learning.

Diferente do Data Warehouse, o Data Lake adota o conceito de schema**-on-read**, onde a estrutura dos dados é definida no momento do consumo.

DATA WAREHOUSE X DATA LAKE: UMA VISÃO EVOLUTIVA DA ARQUITETURA DE DADOS

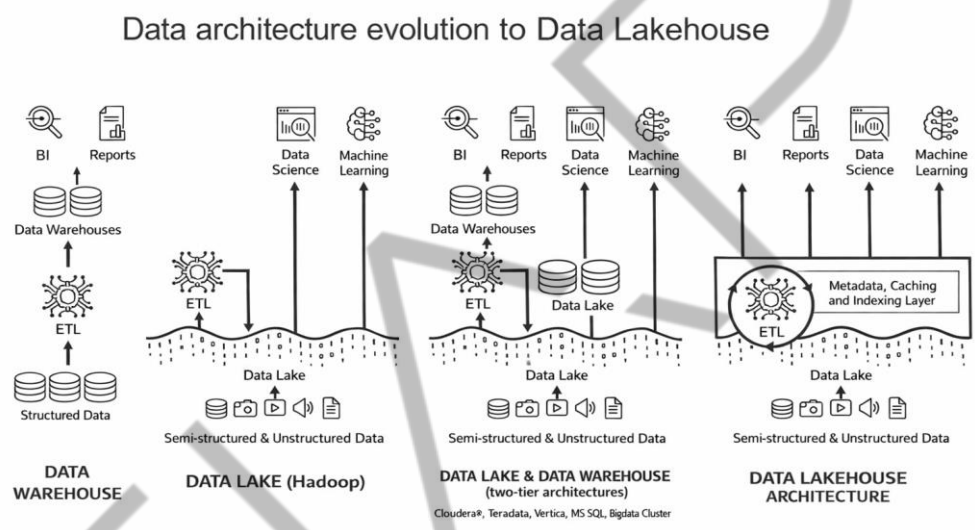


Figura 7 - Data Warehouse X Data Lake
Fonte: Elaborado pelo autor (2026)

A evolução das arquiteturas de dados reflete diretamente a transformação da forma como as organizações utilizam informação para gerar valor. Inicialmente, o foco estava em consolidar dados estruturados para relatórios gerenciais. Com o tempo, surgiram novas demandas analíticas, novos tipos de dados e a necessidade de respostas mais rápidas e preditivas. Esse movimento levou à transição de arquiteturas tradicionais para modelos mais flexíveis e, posteriormente, para arquiteturas unificadas.

Essa evolução não ocorreu por modismo tecnológico, mas como resposta prática ao crescimento exponencial do volume de dados, à diversidade de formatos e

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

à necessidade de análises cada vez mais avançadas, indo além do simples reporte histórico.

DATA WAREHOUSE: O PILAR DA ANÁLISE ESTRUTURADA E CONFIÁVEL

O Data Warehouse representa a primeira grande consolidação da arquitetura analítica corporativa. Ele foi projetado para armazenar **dados estruturados**, provenientes de sistemas transacionais como ERPs, CRMs e sistemas financeiros. Antes de serem armazenados, esses dados passam por processos rigorosos de **ETL (Extract, Transform, Load)**, garantindo padronização, qualidade e integração.

Essa abordagem oferece benefícios claros para o negócio, como:

- Alta consistência e confiabilidade das informações.
- Forte governança e controle dos dados.
- Excelente desempenho para consultas analíticas, BI e relatórios.

No entanto, o Data Warehouse é naturalmente orientado a análises históricas, respondendo principalmente à pergunta **“o que aconteceu?”**. A inclusão de novos tipos de dados ou novas perguntas analíticas costuma exigir mudanças estruturais nos pipelines e nos modelos, tornando essa arquitetura menos flexível frente a cenários de inovação, dados não estruturados e análises avançadas.

DATA LAKE: FLEXIBILIDADE, ESCALA E EXPLORAÇÃO ANALÍTICA

Com o crescimento de dados semiestruturados e não estruturados — como logs, eventos, arquivos de mídia e dados de sensores — surgiu a necessidade de uma arquitetura mais flexível. O Data Lake atende a esse cenário ao permitir o armazenamento de **dados em seu formato bruto**, independentemente de estrutura.

Nessa abordagem, o Data Lake torna-se a base central da arquitetura de dados, possibilitando:

- Exploração direta por equipes de Data Science.
- Acesso a grandes volumes de dados históricos para Machine Learning.
- Transformação seletiva de dados para consumo analítico tradicional.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O conceito de **schema-on-read** é um dos principais diferenciais do Data Lake, pois a estrutura dos dados é definida apenas no momento do uso. Isso amplia significativamente a capacidade de experimentação e inovação, mas também traz desafios importantes relacionados à governança, catalogação e qualidade dos dados. Sem controles adequados, o Data Lake pode perder valor e se tornar um repositório desorganizado, conhecido como *data swamp*.

Nesse contexto, o Data Warehouse não desaparece, mas passa a atuar como uma camada de consumo refinado, alimentada por dados preparados a partir do Data Lake.

DATA LAKEHOUSE: A CONVERGÊNCIA ENTRE CONTROLE E FLEXIBILIDADE

A arquitetura de **Data Lakehouse** surge como uma resposta à complexidade crescente dos ambientes híbridos. Seu objetivo é unificar os pontos fortes do Data Warehouse e do Data Lake em uma única arquitetura coerente.

No modelo Lakehouse:

- Os dados permanecem armazenados no Data Lake.
- Existe uma camada explícita de metadados, governança e controle.
- O mesmo conjunto de dados pode ser utilizado para BI, relatórios, Data Science e Machine Learning.
- Consultas analíticas SQL são executadas diretamente sobre o lake, com desempenho.

Essa convergência reduz a duplicação de dados, simplifica pipelines, diminui custos operacionais e acelera o tempo entre ingestão e geração de insights. Tecnologias modernas permitem aplicar controle de esquema, versionamento, transações ACID, auditoria e otimização de performance diretamente sobre o Data Lake.

A evolução arquitetural em perspectiva

De forma consolidada, essa evolução arquitetural atende a necessidades específicas ao longo do tempo:

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- **Data Warehouse** resolve a necessidade de análises estruturadas, governadas e confiáveis.
- **Data Lake** atende à necessidade de escala, diversidade de dados e inovação analítica.

  Data Lakehouse resolve a fragmentação arquitetural, unificando consumo analítico e exploração avançada.

Essa transição representa uma mudança de mentalidade: de arquiteturas rígidas e centradas exclusivamente em BI para arquiteturas **data-driven**, capazes de sustentar decisões operacionais, estratégicas e preditivas dentro de um único ecossistema de dados.

Conexão com o papel do arquiteto de Big Data

Para o arquiteto de Big Data, compreender essa evolução é essencial. A decisão arquitetural moderna não é mais escolher entre Data Lake ou Data Warehouse, mas **definir como essas abordagens se combinam** de forma eficiente e sustentável.

Essa decisão deve considerar:

- Casos de uso e objetivos do negócio.
- Requisitos de governança, segurança e compliance.
- Custos de armazenamento e processamento.
- Escalabilidade e desempenho das soluções.
- Maturidade analítica e organizacional da empresa.

Arquiteturas modernas não descartam modelos anteriores — elas **absorvem, estendem e evoluem** esses conceitos para atender às demandas atuais e futuras do uso de dados.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

MERCADO, CASES E TENDÊNCIAS

A forma como as organizações arquitetam seus dados evoluiu significativamente nos últimos anos. O aumento do volume de dados, a diversidade de formatos e a necessidade de análises mais rápidas e avançadas impulsionaram mudanças profundas nas arquiteturas corporativas. Hoje, Data Warehouse, Data Lake e Data Lakehouse não são apenas escolhas técnicas, mas decisões estratégicas que impactam diretamente competitividade, inovação e eficiência operacional.

Arquiteturas modernas no mercado

Empresas data-driven adotam arquiteturas híbridas, nas quais o **Data Lake** atua como repositório central de dados e o **Data Warehouse** permanece como camada analítica governada para BI e relatórios executivos. Esse modelo permite atender, simultaneamente, áreas de negócio, analytics avançado e ciência de dados, reduzindo silos e duplicação de dados.

Plataformas unificadas, como o **Databricks**, ganharam destaque ao viabilizar o conceito de **Lakehouse**, oferecendo governança, performance analítica e flexibilidade no mesmo ambiente. Esse movimento tem reduzido a complexidade arquitetural e acelerado o tempo entre ingestão e geração de valor.

A evolução das arquiteturas de dados tem sido amplamente discutida por especialistas da indústria e da academia, refletindo a necessidade crescente de arquiteturas mais flexíveis, escaláveis e orientadas a múltiplos tipos de análise. Para aprofundar esse debate e conectar o conteúdo da aula com o que há de mais atual no mercado, recomenda-se o acompanhamento de materiais que abordam tanto os fundamentos quanto as tendências emergentes da área.

Artigo recomendado

Databricks Lakehouse Data Modeling: Myths, Truths, and Best Practices: Artigo que discute como conceitos clássicos de modelagem (Kimball e Inmon) são aplicados e reinterpretados em arquiteturas Lakehouse, apresentando boas práticas para ambientes modernos de dados.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Podcast recomendado

Data Engineering Podcast: Podcast voltado a arquiteturas modernas de dados, abordando temas como Data Lake, Data Warehouse, Lakehouse, engenharia de dados e analytics em escala, sempre com convidados atuantes no mercado.

Livro recomendado

The Data Warehouse Toolkit – Ralph Kimball

Livro clássico que fundamenta a modelagem dimensional e continua sendo referência para arquiteturas analíticas modernas, inclusive em contextos de Data Lakehouse.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você compreendeu que **arquitetura de dados é uma decisão estratégica**, capaz de impactar diretamente a forma como as organizações transformam dados em valor de negócio.

Você conheceu os principais pensadores que fundamentaram a área de Data Warehousing, **Ralph Kimball e Bill Inmon**, entendendo suas abordagens, diferenças conceituais e como suas modelagens influenciam arquiteturas analíticas até os dias atuais.

Explorou, de forma teórica e prática, a **evolução das arquiteturas de dados**, desde o **Data Warehouse tradicional**, passando pelo surgimento do **Data Lake**, até chegar ao conceito moderno de **Data Lakehouse**, que unifica governança, flexibilidade e múltiplos tipos de consumo analítico.

Por fim, você conectou teoria, prática e mercado, entendendo que arquiteturas modernas **não substituem modelos anteriores**, mas os **absorvem e evoluem**, e que o papel do arquiteto de Big Data é justamente decidir **como combinar essas abordagens** de acordo com objetivos de negócio, governança, custo e maturidade analítica da organização.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

REFERÊNCIAS

DATABRICKS. **Databricks Free Edition**. Disponível em: https://www.databricks.com/learn/free-edition. Acesso em: 26 fev. 2026.

DATABRICKS. **Databricks Lakehouse Data Modeling**: Myths, Truths, and Best Practices. 2023. Disponível em: https://www.databricks.com/blog/databricks-lakehouse-data-modeling-myths-truths-and-best-practices. Acesso em: 26 fev. 2026.

DATABRICKS. **Introduction to Databricks**. Disponível em: https://docs.databricks.com/en/introduction/. Acesso em: 26 fev. 2026.

DATABRICKS. **What is a Data Lakehouse?.** 2020. Disponível em: https://www.databricks.com/blog/2020/01/30/what-is-a-data-lakehouse.html. Acesso em: 26 fev. 2026.

INMON, W. H. **Building the Data Warehouse**. Hoboken: John Wiley & Sons, 2005.

KIMBALL, R. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling.** Hoboken: John Wiley & Sons, 2013.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

PALAVRAS-CHAVE

Data Warehouse. Data Lake. Databricks.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com