

AI SCIENTIST

FASE 2 | AULA 04 -

BANCO VETORIAL

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SUMÁRIO

O QUE VEM POR AÍ? 3
HANDS ON 4
SAIBA MAIS 8
MERCADO, CASES E TENDÊNCIAS 15
O QUE VOCÊ VIU NESTA AULA? 17
REFERÊNCIAS 18

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VEM POR AÍ?

Se até aqui você trabalhou com dados estruturados, consultas exatas e modelos bem definidos, prepare-se para dar um salto conceitual. Bancos Vetoriais surgem como resposta direta a um mundo onde dados não estruturados — textos, imagens, áudios e embeddings gerados por modelos de IA — passam a ser o principal ativo. Em vez de buscar “igualdade”, esses bancos permitem encontrar **similaridade**, abrindo espaço para perguntas muito mais próximas da forma como humanos pensam e se comunicam.

Você vai entender como Bancos Vetoriais se conectam ao avanço da Inteligência Artificial, especialmente em aplicações como busca semântica, recomendação inteligente e arquiteturas modernas de IA generativa. Vamos explorar por que esse tipo de banco deixou de ser tendência para se tornar peça central em soluções data-driven, e como ele muda completamente a forma de armazenar, consultar e extrair valor dos dados. Aqui começa a transição do query tradicional para o pensar por proximidade.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

HANDS ON

Neste hands on, você vai construir um mini pipeline de Banco Vetorial usando Python, indo da criação dos embeddings até a busca por similaridade semântica. O objetivo é entender o que acontece em cada etapa, não apenas rodar código.

Preparando o ambiente

Vamos assumir um ambiente local ou notebook (Jupyter/Colab). As bibliotecas abaixo são amplamente usadas em projetos reais.

```
pip install sentence-transformers faiss-cpu pandas
```

Aqui usamos:

- `sentence-transformers` para gerar embeddings de texto;
- `faiss` para indexação e busca vetorial;
- `pandas` apenas para organizar os dados.

Criando um conjunto de dados simples

Imagine que você tem pequenas descrições, como FAQs, produtos ou documentos internos.

```
import pandas as pd


dados = [
    "Banco vetorial permite busca por similaridade semântica",
    "SQL é usado para consultas estruturadas em bancos relacionais",
    "Embeddings transformam texto em vetores numéricos",
    "Bancos NoSQL escalam grandes volumes de dados",
```

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

```
        "Busca semântica vai além da correspondência exata de palavras"
    ]


    df = pd.DataFrame(dados, columns=["texto"])
    df
```

Código fonte1 – Exemplo de código fonte python

Fonte: Elaborado pelo autor (2026)

Ponto-chave: até aqui, os dados ainda são texto puro. Bancos Vetoriais não operam diretamente sobre strings, mas sobre vetores.

Gerando embeddings (o coração do processo)

Agora vamos transformar cada texto em um vetor numérico usando um modelo pré-treinado.

```
    from sentence_transformers import SentenceTransformer
    modelo = SentenceTransformer("all-MiniLM-L6-v2")
    embeddings = modelo.encode(df["texto"].tolist())
```

Código fonte2 – Exemplo de código fonte python

Fonte: Elaborado pelo autor (2026)

Cada linha agora virou um vetor de centenas de dimensões. Esses vetores posicionam os textos em um espaço semântico, onde textos parecidos ficam próximos.

Criando o índice vetorial

Aqui entra o papel do Banco Vetorial. Vamos usar FAISS, muito comum em protótipos e sistemas de recomendação.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

```
import faiss
import numpy as np


dimensao = embeddings.shape[1]
index = faiss.IndexFlatL2(dimensao)


index.add(np.array(embeddings))
print("Total de vetores indexados:", index.ntotal)
```

Código fonte3 – Exemplo de código fonte python

Fonte: Elaborado pelo autor (2026)

Reflexão importante:

- **Não há tabelas;**
- **Não há chaves primárias;**
- **Há apenas vetores e uma métrica de distância.**

Realizando uma busca semântica

Agora vem a mágica. Vamos buscar textos semanticamente parecidos, mesmo sem repetir as mesmas palavras.

```
consulta = "Como funciona pesquisa por significado em textos?"
consulta_embedding = modelo.encode([consulta])


distancias, indices = index.search(
    np.array(consulta_embedding),
    k=2
)
```

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Código fonte4 – Exemplo de código fonte python

Fonte: Elaborado pelo autor (2026)

Interpretando o resultado

```
for i in indices[0]:

    print("-", df.iloc[i]["texto"])
```

Código fonte5 – Exemplo de código fonte python

Fonte: Elaborado pelo autor (2026)

Você deve notar que os textos retornados fazem sentido conceitual, mesmo que não tenham as mesmas palavras da consulta.

Aqui está o grande diferencial do Banco Vetorial: a busca é feita por proximidade semântica, não por igualdade.

Conectando com o mundo real

Esse mesmo fluxo é usado em:

- Buscas inteligentes em portais corporativos;
- Sistemas de recomendação;
- Chatbots com recuperação de contexto;
- Arquiteturas de IA generativa com RAG (Retrieval-Augmented Generation).

Em ambientes produtivos, o FAISS pode ser substituído por soluções gerenciadas como Pinecone, Weaviate ou Chroma, mas o conceito central é exatamente o mesmo.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SAIBA MAIS

Os Bancos Vetoriais surgem como resposta direta à transformação do tipo de dado que as organizações passaram a produzir e consumir. Em um cenário dominado por textos livres, imagens, áudios, vídeos e informações contextuais, torna-se cada vez mais limitada a capacidade dos bancos de dados tradicionais de representar e consultar significado. Bancos Vetoriais partem de um princípio distinto: dados não precisam ser apenas armazenados, mas **compreendidos matematicamente**.

Diferentemente de modelos baseados em igualdade ou ordenação, Bancos Vetoriais operam sobre **proximidade semântica**. Isso significa que o valor de um dado não está apenas em seu conteúdo literal, mas na relação que ele mantém com outros dados. Essa mudança de paradigma impacta diretamente a forma como sistemas de busca, recomendação, análise de contexto e Inteligência Artificial são construídos.

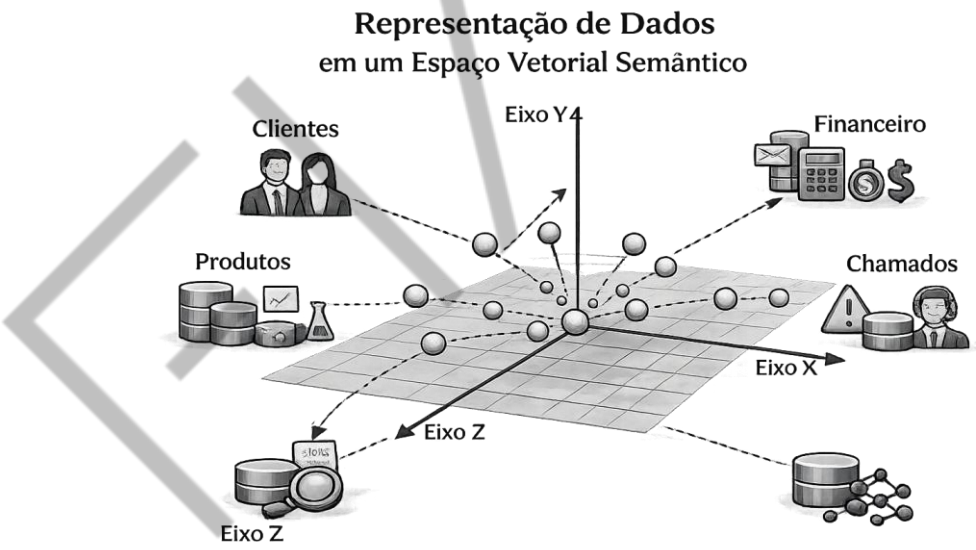


Figura 1 – Representação de dados

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

Nesse contexto, o dado deixa de ser visto como um registro isolado e passa a ser interpretado como um ponto em um espaço matemático de alta dimensionalidade. Quanto mais próximos dois pontos estão nesse espaço, maior é a similaridade

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

semântica entre os dados que eles representam. Essa ideia é fundamental para entender por que Bancos Vetoriais são especialmente adequados para problemas onde o significado é subjetivo, contextual e aproximado.

Embeddings: a base matemática do significado

O conceito de **embedding** é o alicerce técnico dos Bancos Vetoriais. Um embedding é uma representação vetorial densa, geralmente gerada por modelos de aprendizado profundo, capaz de capturar relações semânticas complexas presentes nos dados. Em vez de trabalhar com palavras, pixels ou sons de forma direta, esses modelos aprendem a projetar informações em vetores numéricos que preservam significado.

No caso de textos, embeddings conseguem representar sinônimos, intenções e contextos semelhantes de forma próxima no espaço vetorial, mesmo quando as palavras utilizadas são diferentes. Esse comportamento é resultado do treinamento desses modelos em grandes volumes de dados, onde padrões estatísticos e semânticos são aprendidos de forma distribuída ao longo das dimensões do vetor.

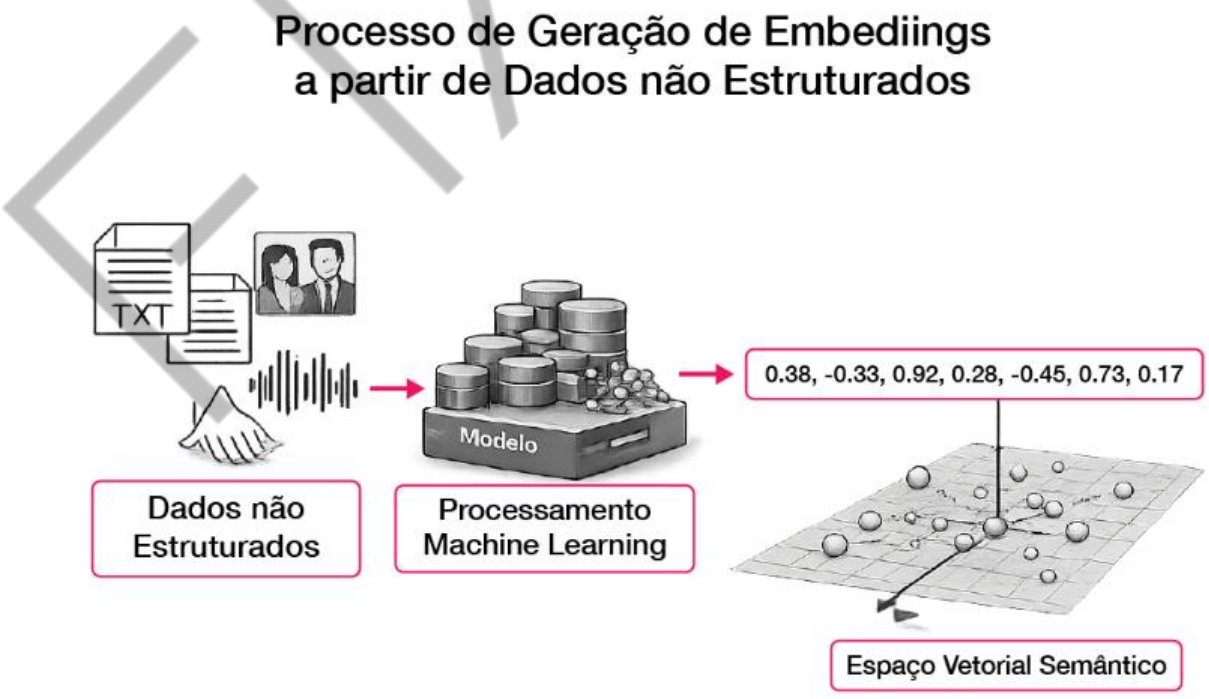


Figura 2 – Embeddings

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Uma característica importante dos embeddings é que nenhuma dimensão isolada possui significado explícito. O sentido emerge da combinação de todas as dimensões, o que torna essas representações extremamente expressivas, porém menos interpretáveis. Essa opacidade exige novos cuidados em projetos de dados, especialmente quando embeddings passam a representar documentos sensíveis ou decisões críticas de negócio.

Além disso, embeddings permitem uma abordagem multimodal. Textos, imagens e áudios podem ser convertidos para o mesmo espaço vetorial, possibilitando consultas cruzadas, como buscar imagens a partir de descrições textuais ou recuperar documentos com base em perguntas feitas em linguagem natural.

Métricas de similaridade e o conceito de proximidade

Uma vez que os dados são representados como vetores, o próximo desafio é medir quão próximos eles estão entre si. Bancos Vetoriais utilizam **métricas de similaridade**, que substituem os operadores tradicionais de igualdade utilizados em SQL. Entre as métricas mais comuns estão a similaridade do cosseno, a distância euclidiana e o produto interno.

A similaridade do cosseno mede o ângulo entre dois vetores e é amplamente utilizada em aplicações de processamento de linguagem natural, pois foca no alinhamento semântico entre os dados. Já a distância euclidiana considera a distância geométrica direta no espaço vetorial, sendo útil quando a magnitude do vetor também carrega informação relevante. A escolha da métrica impacta diretamente a experiência do usuário e a qualidade percebida dos resultados.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

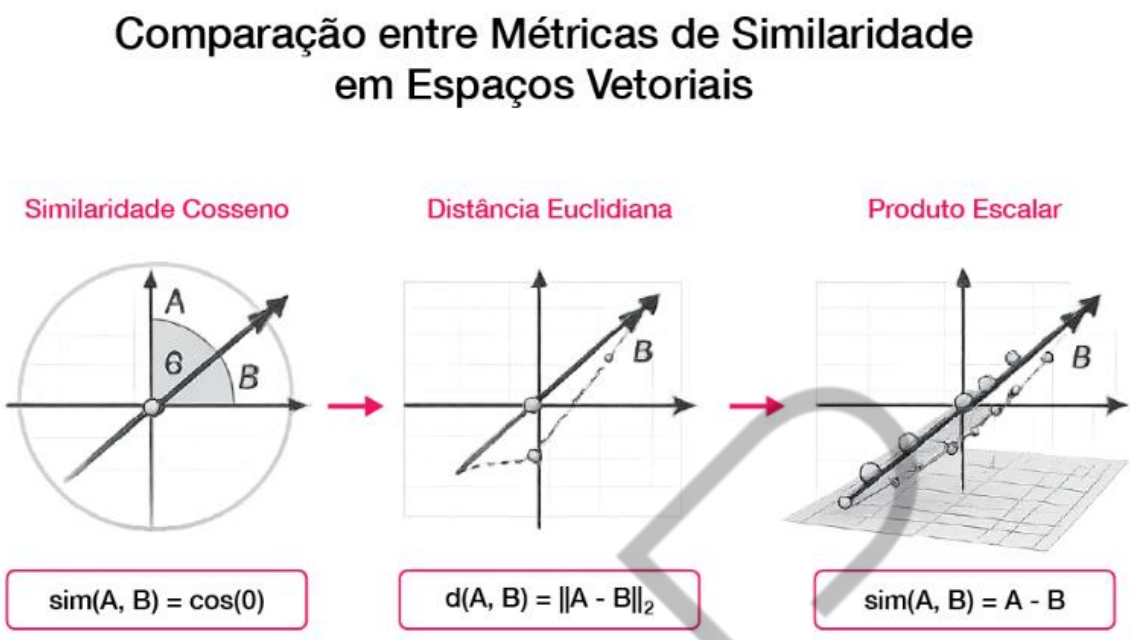


Figura 3 – Comparação entre métricas de similaridade em espaços vetoriais

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

Esse modelo de busca introduz um novo paradigma: os resultados deixam de ser exatos e passam a ser **ordenados por relevância**. Isso exige uma mudança de mentalidade tanto no desenvolvimento de sistemas quanto na forma como usuários interagem com dados, aceitando que respostas são probabilísticas e contextuais.

Indexação vetorial e busca aproximada

Buscar similaridade em espaços de alta dimensionalidade é computacionalmente custoso. Uma busca exaustiva, comparando cada vetor com todos os outros, rapidamente se torna inviável à medida que o volume de dados cresce. Para resolver esse problema, Bancos Vetoriais utilizam técnicas conhecidas como **Approximate Nearest Neighbors (ANN)**.

Essas técnicas constroem estruturas de índice que permitem localizar vetores próximos de forma eficiente, sacrificando uma pequena parcela de precisão em troca de ganhos significativos de desempenho. Métodos como IVF particionam o espaço vetorial, enquanto abordagens baseadas em grafos, como HNSW, criam redes de conexões entre vetores semanticamente próximos.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

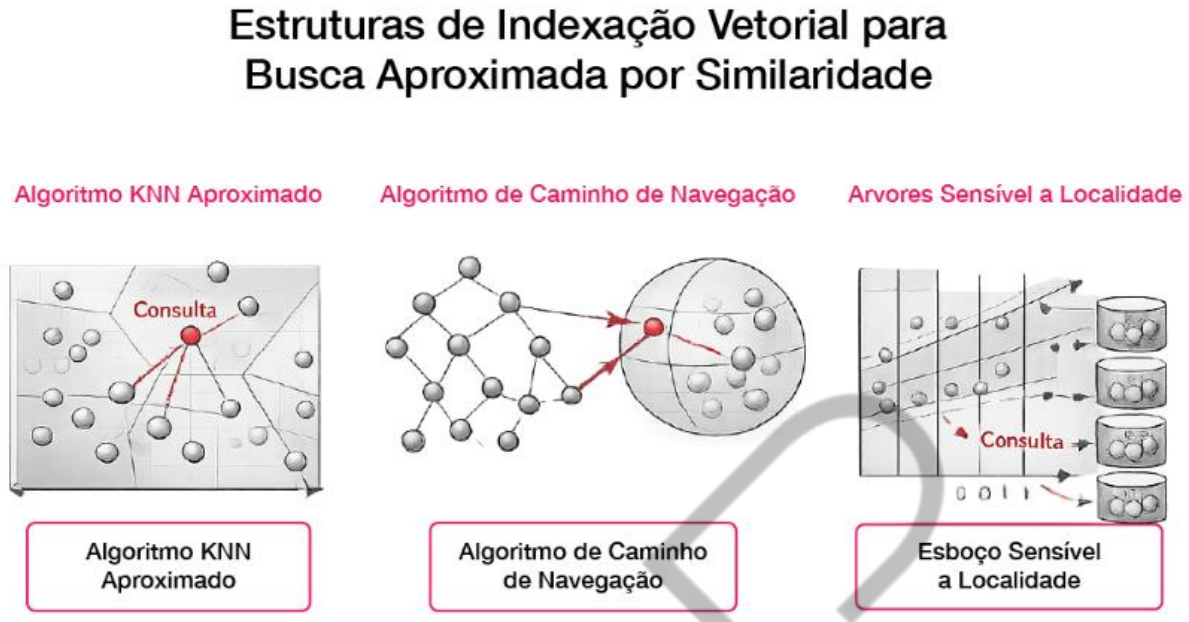


Figura 4 – Estruturas de indexação vetorial

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

Bibliotecas como **FAISS** tornaram essas técnicas acessíveis para pesquisa e indústria, enquanto soluções gerenciadas como **Pinecone**, **Weaviate** e **Chroma** abstraem a complexidade operacional, permitindo escalar Bancos Vetoriais em ambientes produtivos.

Bancos Vetoriais e IA Generativa (RAG)

O crescimento recente dos Bancos Vetoriais está profundamente ligado à evolução da Inteligência Artificial Generativa. Em arquiteturas modernas, especialmente no padrão conhecido como **Retrieval-Augmented Generation (RAG)**, o Banco Vetorial atua como uma memória semântica externa. Antes de gerar uma resposta, o modelo consulta o Banco Vetorial para recuperar informações relevantes, que são então utilizadas como contexto.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

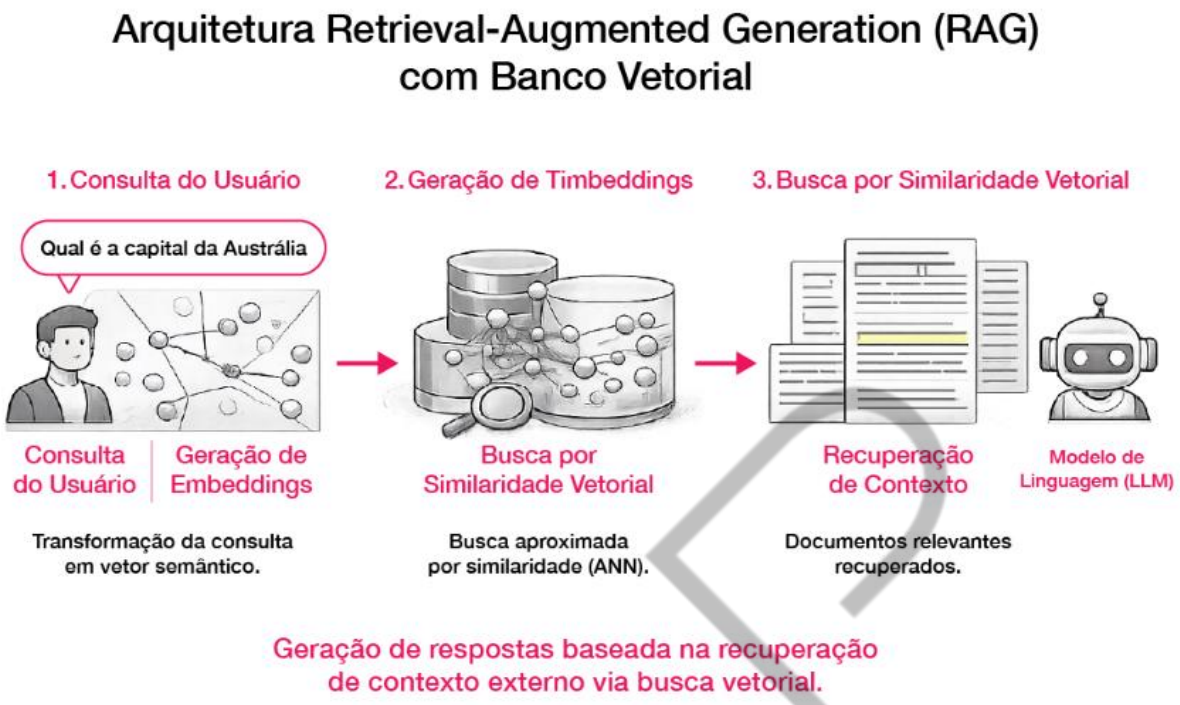


Figura 5 – Arquitetura Retrieval-Augmented Generation (RAG)

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

Esse padrão reduz significativamente problemas como alucinação e falta de contextualização, permitindo que modelos respondam com base em dados atualizados e específicos da organização. Assim, o Banco Vetorial deixa de ser apenas um mecanismo de busca e passa a desempenhar um papel estratégico na arquitetura de dados corporativa.

Convivência com bancos tradicionais e persistência poliglota

Bancos Vetoriais não substituem bancos relacionais ou NoSQL. Eles fazem parte de uma **arquitetura de persistência poliglota**, onde cada tecnologia é utilizada de acordo com sua vocação. Bancos relacionais continuam sendo essenciais para transações e integridade, enquanto Bancos Vetoriais lidam com contexto, similaridade e significado.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

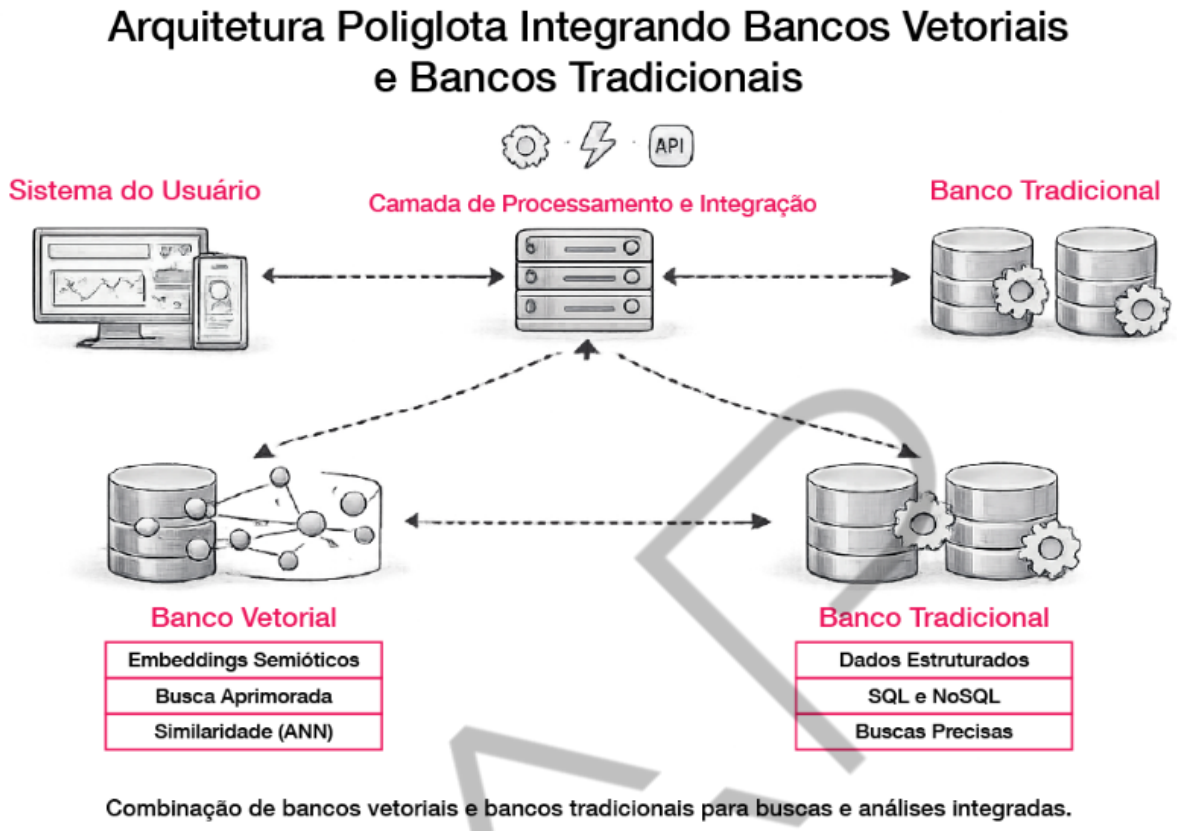


Figura 6 – Arquitetura poliglota

Fonte: Elaborado pelo autor via Inteligência Artificial (2026)

Essa convivência exige novos cuidados arquiteturais, como sincronização entre dados estruturados e embeddings, além de mecanismos de governança para garantir segurança, qualidade semântica e conformidade regulatória.

Desafios, governança e qualidade semântica

Apesar de suas vantagens, Bancos Vetoriais introduzem desafios relevantes. Embeddings podem reproduzir vieses dos dados de treinamento, e sua natureza opaca dificulta auditorias tradicionais. Além disso, avaliar qualidade deixa de ser apenas medir performance técnica e passa a envolver critérios subjetivos, como relevância percebida.

Nesse sentido, a adoção de Bancos Vetoriais exige maturidade organizacional, colaboração entre áreas técnicas e de negócio e uma nova forma de pensar governança de dados. Mais do que uma inovação tecnológica, eles representam uma **mudança cultural na forma de tratar informação**.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

MERCADO, CASES E TENDÊNCIAS

A consolidação dos Bancos Vetoriais no mercado está diretamente associada ao avanço da Inteligência Artificial e, sobretudo, à adoção em larga escala de modelos de linguagem. O crescimento de aplicações baseadas em busca semântica, recomendação contextual e IA generativa fez com que organizações passassem a enxergar o Banco Vetorial como **infraestrutura essencial**, e não apenas como um componente experimental.

Esse movimento é bem descrito em materiais introdutórios do próprio mercado, como o artigo What is a Vector Database? publicado pela Pinecone, que contextualiza o papel dessas bases como camada fundamental para aplicações orientadas a significado (https://www.pinecone.io/learn/vector-database/).

Na prática, empresas vêm adotando Bancos Vetoriais como complemento às suas plataformas analíticas tradicionais. Data Lakes e Data Warehouses continuam sendo o núcleo da persistência de dados estruturados, enquanto as bases vetoriais assumem a responsabilidade de lidar com contexto, linguagem natural e similaridade. Esse desenho arquitetural dialoga diretamente com os princípios apresentados por Martin Kleppmann em Designing Data-Intensive Applications (O'Reilly, 2017), obra amplamente reconhecida por discutir como diferentes modelos de armazenamento coexistem em arquiteturas modernas e escaláveis.

Um dos **cases mais relevantes do mercado** está no uso de Bancos Vetoriais em arquiteturas de **Retrieval-Augmented Generation (RAG)**. Nesse padrão, documentos corporativos são transformados em embeddings e armazenados em uma base vetorial, que passa a ser consultada antes da geração de respostas por um modelo de linguagem. Essa abordagem foi formalizada no artigo Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, publicado pela Meta AI, que demonstra como a recuperação semântica melhora significativamente a qualidade e a confiabilidade das respostas geradas por modelos de NLP (https://ai.facebook.com/blog/retrieval-augmented-generation-streamlining-the-creation-of-intelligent-natural-language-processing-models/).

No ecossistema de fornecedores, observa-se uma rápida especialização das soluções. Plataformas como **Pinecone** (https://www.pinecone.io), **Weaviate**

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

(https://weaviate.io) e **Chroma** (https://www.trychroma.com) oferecem Bancos Vetoriais gerenciados, com foco em escalabilidade, baixa latência e integração direta com frameworks de IA. Em paralelo, soluções open source como **FAISS** (https://github.com/facebookresearch/faiss) continuam sendo amplamente utilizadas em ambientes acadêmicos e corporativos, especialmente em cenários que demandam maior controle sobre a indexação e a infraestrutura.

Outra tendência clara é a aproximação entre Bancos Vetoriais e práticas consolidadas de engenharia de machine learning. O livro *Designing Machine Learning Systems*, de Saleema Amershi et al. (O'Reilly, 2022), discute como sistemas de ML em produção exigem pipelines robustos, observabilidade e integração contínua com dados — contexto no qual Bancos Vetoriais passam a atuar como camada estratégica para recuperação de conhecimento e contextualização de modelos.

Além disso, cresce o interesse por **buscas multimodais**, nas quais textos, imagens e áudios coexistem no mesmo espaço vetorial. Essa tendência amplia significativamente as possibilidades de negócio, permitindo, por exemplo, pesquisar imagens a partir de descrições textuais ou recuperar documentos técnicos a partir de perguntas em linguagem natural. Conteúdos educacionais, como o vídeo *Vector Databases Explained*, publicado pelo time do Weaviate no YouTube (https://www.youtube.com/watch?v=klTvEwg3oJ4), ajudam a visualizar como essas arquiteturas estão sendo aplicadas em cenários reais.

Por fim, o mercado passa a discutir com mais profundidade temas como **governança semântica, viés e qualidade de resultados**. À medida que Bancos Vetoriais passam a influenciar decisões automatizadas e experiências do usuário, torna-se essencial avaliar não apenas desempenho técnico, mas também relevância, explicabilidade e aderência ao contexto de negócio. Essa discussão aponta para um futuro em que Bancos Vetoriais deixam de ser apenas uma inovação tecnológica e se consolidam como um pilar das arquiteturas modernas de dados e Inteligência Artificial.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você compreendeu como os **Bancos Vetoriais** surgem como resposta às limitações dos modelos tradicionais de armazenamento e consulta quando o foco passa a ser **significado, contexto e similaridade**. Foi possível perceber que, diferentemente dos bancos relacionais e NoSQL clássicos, essas bases operam sobre representações vetoriais de dados não estruturados, permitindo buscas semânticas e análises baseadas em proximidade.

Você também explorou o conceito de **embeddings** como elemento central desse modelo, entendendo como textos, imagens e outros tipos de dados podem ser transformados em vetores numéricos e posicionados em espaços semânticos de alta dimensionalidade. A aula destacou ainda o papel das métricas de similaridade e das técnicas de indexação vetorial, que viabilizam buscas eficientes mesmo em grandes volumes de dados.

Por fim, foram discutidas aplicações práticas e tendências de mercado, como o uso de Bancos Vetoriais em arquiteturas de **IA generativa e Retrieval-Augmented Generation (RAG)**, além de sua convivência com bancos tradicionais em arquiteturas de persistência poliglota. Esse conjunto de conceitos reforça a importância dos Bancos Vetoriais como componente estratégico nas arquiteturas modernas de dados e Inteligência Artificial.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

REFERÊNCIAS

AMERSHI, Saleema; BEGEL, Andrew; BIRD, Christian et al. ***Designing Machine Learning Systems***. Sebastopol: O'Reilly Media, 2022.

CHROMA. ***Chroma Documentation***. Chroma DB, 2024. Disponível em: https://docs.trychroma.com/. Acesso em: 09 abr. 2026.

JOHNSON, Jeff; DOUZE, Matthijs; JÉGOU, Hervé. **Billion-scale similarity search with GPUs.** ***IEEE Transactions on Big Data***, v. 7, n. 3, p. 535–547, 2021. (Base conceitual do FAISS e técnicas de busca aproximada por vizinhança).

KLEPPMANN, Martin. ***Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems***. Sebastopol: O'Reilly Media, 2017.

LEWIS, Patrick; OGAZIO, Ethan; GRAVE, Edouard; RIEDEL, Sebastian. **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.** ***Meta AI Research***, 2020. Disponível em: https://ai.facebook.com/blog/retrieval-augmented-generation-streamlining-the-creation-of-intelligent-natural-language-processing-models/. Acesso em: 09 abr. 2026.

META AI. ***FAISS: A Library for Efficient Similarity Search***. GitHub, 2023. Disponível em: https://github.com/facebookresearch/faiss. Acesso em: 09 abr. 2026.

PINECONE. ***What is a Vector Database?*** Pinecone Learn, 2023. Disponível em: https://www.pinecone.io/learn/vector-database/. Acesso em: 09 abr. 2026.

WEAVIATE. ***Vector Databases Explained***. YouTube, 2023. Disponível em: https://www.youtube.com/watch?v=klTvEwg3oJ4. Acesso em: 09 abr. 2026.

WEAVIATE. ***Vector Search Explained***. Weaviate Documentation, 2024. Disponível em: https://weaviate.io/blog/vector-search-explained. Acesso em: 09 abr. 2026.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

PALAVRAS-CHAVE

Busca Semântica. Bancos Vetoriais. Representações Vetoriais.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com