

AI SCIENTIST

FASE 2 | AULA 03 -

CLOUD DATA (AWS S3, GCP BIGQUERY, AZURE DATA LAKE)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SUMÁRIO

O QUE VEM POR AÍ? 3

HANDS ON 4

SAIBA MAIS 9

MERCADO, CASES E TENDÊNCIAS 24

O QUE VOCÊ VIU NESTA AULA? 25

REFERÊNCIAS 26

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VEM POR AÍ?

O conceito de Cloud Data representa uma transformação estrutural na forma como dados são armazenados, processados e consumidos. Mais do que a simples migração de servidores físicos para data centers remotos, Cloud Data define um ecossistema de serviços gerenciados no qual a infraestrutura é abstraída, permitindo que o foco esteja em escalabilidade, governança, análise e geração de valor para o negócio.

Historicamente, as arquiteturas de dados eram baseadas em sistemas monolíticos, nos quais computação e armazenamento estavam rigidamente acoplados. Bancos relacionais e appliances de Data Warehouse exigiam crescimento conjunto de CPU, memória e disco, resultando em baixa elasticidade, alto custo e ineficiência operacional. A computação em nuvem rompe esse paradigma ao introduzir a separação entre computação e armazenamento, princípio fundamental das arquiteturas modernas de dados.

Nesse novo modelo, os dados são persistidos de forma durável e econômica em Object Storage, enquanto a computação é provisionada sob demanda e de forma efêmera. Clusters podem ser criados apenas pelo tempo necessário para executar cargas analíticas intensivas e desligados em seguida, viabilizando elasticidade extrema e otimização financeira, algo impraticável em ambientes tradicionais.

Esse movimento é impulsionado pelo crescimento acelerado do volume de dados, resultado da digitalização, da proliferação de dispositivos conectados e da adoção de inteligência artificial. Nesse contexto, Cloud Data deixa de ser apenas uma escolha tecnológica e passa a representar o modelo dominante de arquitetura de dados. Como aponta a Gartner, a nuvem se consolidou como a base para a inovação digital, permitindo o uso de dados de forma segura, escalável e orientada a valor.

Este módulo introduz esse cenário, preparando você para compreender como e por que os pipelines ETL/ELT evoluem na nuvem, e qual é o papel do Cloud Data nas arquiteturas modernas orientadas a dados, explorando as abordagens dos principais provedores do mercado: AWS, GCP e Azure.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

HANDS ON

Laboratório Teórico: Arquitetura de Cloud Data

Contexto do Problema

Você faz parte de uma empresa de médio porte do setor de varejo digital. A empresa opera um e-commerce nacional, com crescimento acelerado de vendas, campanhas sazonais frequentes e forte investimento em analytics e inteligência artificial para personalização da experiência do cliente.

Atualmente, a organização enfrenta dificuldades para escalar suas análises de dados. O ambiente existente é majoritariamente on-premises, com um Data Warehouse tradicional que recebe cargas noturnas em batch. Esse modelo não atende mais às necessidades do negócio, que exige dados mais atualizados, maior flexibilidade analítica e redução de custos operacionais.

A liderança decide, então, iniciar a modernização da arquitetura de dados, adotando uma estratégia baseada em Cloud Data.

Critérios de Decisão Arquitetural

Antes de escolher uma estratégia de migração, é fundamental avaliar o workload a partir dos seguintes critérios:

- **Criticidade para o negócio**: o sistema é essencial para a operação diária? Impacta diretamente receita ou clientes?
- **Complexidade técnica atual:** o pipeline é simples, legado, fortemente acoplado ou já modularizado?
- **Volume e crescimento dos dados:** o volume cresce rapidamente? Há picos sazonais ou cargas imprevisíveis?
- **Necessidade de escalabilidade e elasticidade:** o workload se beneficia de computação sob demanda?
- **Custo operacional atual:** a manutenção do ambiente atual é alta? Exige muito esforço manual?

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- **Horizonte de longo prazo:** esse pipeline será base para analytics avançado, IA ou novos produtos de dados?

Com essas perguntas respondidas, podemos utilizar as estratégias de Migração para a Nuvem – Os 6 Rs

Estratégia	Descrição	Exemplo prático	Quando utilizar
Rehost (Lift and Shift)	Migração direta da infraestrutura existente para a nuvem, sem alterações relevantes na arquitetura ou no código.	Mover um banco de dados ou job on-premise para uma VM na nuvem.	Quando há necessidade de migração rápida, com baixo risco e pouco tempo para reengenharia.
Replatform (Lift and Reshape)	Migração com pequenas adaptações para uso de serviços gerenciados, mantendo a lógica principal da aplicação.	Migrar um cluster Hadoop local para Amazon EMR ou Google Dataproc.	Quando se deseja reduzir o esforço operacional sem reescrever totalmente o sistema.
Refactor (Re-architect)	Reescrita da solução para um modelo cloud-native, explorando separação de computação e armazenamento e serviços serverless.	Substituir jobs legados por pipelines PySpark em AWS Glue ou Google Dataflow.	Quando o objetivo é escalabilidade, eficiência e inovação no longo prazo.
Repurchase	Substituição da solução atual por um produto ou serviço SaaS nativo em nuvem.	Trocar um ETL on-premise por uma ferramenta SaaS de integração de dados.	Quando há soluções de mercado maduras que atendem ao negócio com menor custo operacional.
Retain	Manutenção do workload no ambiente atual (on-premise ou legado).	Manter sistemas críticos que não podem ser migrados no curto prazo.	Quando existem restrições técnicas, legais ou estratégicas para a migração.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Retire	Descontinuação do sistema ou pipeline que não agrega mais valor ao negócio.	Desativar pipelines antigos sem uso ou redundantes.	Quando o custo de manter supera o valor gerado.

Etapas do Laboratório

1. Escolha da Estratégia de Migração (6 Rs)

Antes de pensar em ferramentas, você deve decidir como o pipeline será migrado.

Nesta etapa, você deve analisar o cenário apresentado e definir qual estratégia de migração melhor atende às necessidades da empresa. Considere se o objetivo é apenas sair rapidamente do ambiente on-premises, reduzir o esforço operacional ou, de fato, construir uma arquitetura moderna, escalável e preparada para o futuro.

Explique qual estratégia dos 6 Rs você adotaria para o pipeline principal de dados e justifique sua decisão considerando criticidade para o negócio, crescimento esperado, custo operacional atual e horizonte de longo prazo.

2. Definição da Estratégia de Armazenamento de Dados

Com a estratégia de migração definida, o próximo passo é pensar como os dados serão armazenados, independentemente de tecnologia ou cloud específica.

Nesta etapa, você deve descrever:

- Como os dados serão organizados ao longo do tempo;
- Se haverá separação entre dados brutos, tratados e analíticos;
- Ccomo o armazenamento deve suportar reprocessamento, auditoria e evolução do pipeline.

Explique por que uma arquitetura baseada em separação entre computação e armazenamento é adequada para o cenário e como isso impacta escalabilidade e custo.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

3. Política de Retenção e Ciclo de Vida dos Dados

Nem todos os dados precisam ser armazenados indefinidamente da mesma forma. Definir tempo de retenção é uma decisão essencial de arquitetura e governança.

Nesta etapa, descreva:

- Por quanto tempo os dados brutos devem ser mantidos;
- Quando dados podem ser agregados, arquivados ou descartados;
- Como exigências legais, auditoria e análises históricas influenciam essas decisões.

Explique como uma política clara de retenção contribui para controle de custos e conformidade regulatória.

4. Definição do Modelo de Ingestão dos Dados

A migração para a nuvem representa uma oportunidade para reavaliar a forma como os dados são processados, e não apenas onde eles são armazenados.

Nesta etapa, você deve analisar se o modelo atual de processamento atende às necessidades do negócio ou se há ganhos ao adotar um modelo diferente. Explique quais dados podem continuar sendo processados em batch, quais se beneficiaram de processamento em tempo real e se um modelo híbrido faz mais sentido para a empresa.

Justifique suas decisões considerando latência, valor de negócio, custo e complexidade operacional, lembrando que nem todo dado precisa ser processado em streaming para gerar valor.

5. Orquestração e Fluxo do Pipeline

Com o modelo de ingestão definido, é necessário pensar em como o pipeline será coordenado. A orquestração garante que as etapas do processamento ocorram na ordem correta, que falhas sejam tratadas e que o pipeline seja observável.

Nesta etapa, descreva como o pipeline deve ser orquestrado, considerando dependências entre etapas, reprocessamento, controle de falhas e agendamento. Explique por que a orquestração é um elemento central em arquiteturas de Cloud Data e como ela contribui para confiabilidade e governança.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

6. Segurança, Governança e Observabilidade

Antes de qualquer escolha tecnológica, é fundamental definir como a arquitetura lidará com segurança, governança e monitoramento.

Explique como o controle de acesso aos dados deve ser estruturado, como a rastreabilidade das transformações será garantida e de que forma a qualidade dos dados e a saúde do pipeline serão monitoradas. Considere também aspectos regulatórios, como privacidade e conformidade, e explique como essas preocupações influenciam o desenho da arquitetura.

7. Escolha da Cloud e das Tecnologias

Somente após todas as decisões conceituais anteriores, você deve escolher o provedor de nuvem e as tecnologias que melhor materializam a arquitetura definida.

Nesta etapa, escolha uma cloud (AWS, GCP ou Azure) e explique como os serviços dessa plataforma atendem às decisões já tomadas sobre ingestão, armazenamento, processamento, orquestração e consumo. Justifique suas escolhas mostrando coerência entre necessidade de negócio, arquitetura e tecnologia.

8. Desenho da Arquitetura Final

Com todas as decisões consolidadas, você deverá produzir o desenho arquitetural final da solução, além do diagrama, descreva o fluxo de dados ponta a ponta, explicando como cada decisão tomada anteriormente se reflete na arquitetura final.

Desafio Extra: Implementação de um Pipeline Cloud Data

Neste laboratório prático, você irá implementar uma versão simplificada da arquitetura de Cloud Data definida no laboratório teórico. O objetivo não é apenas executar um pipeline, mas validar na prática as decisões arquiteturais tomadas anteriormente, explorando serviços gerenciados de nuvem, separação entre computação e armazenamento e boas práticas de engenharia de dados. Você poderá escolher AWS, Google Cloud Platform ou Microsoft Azure, priorizando serviços com camada gratuita (free tier) ou alternativas de baixo custo, simulando um cenário realista de aprendizado e prototipação.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SAIBA MAIS

Cloud Data: Definição e Evolução Arquitetural

O conceito de Cloud Data representa uma transformação estrutural na forma como dados são armazenados, processados e consumidos. Mais do que apenas migrar servidores físicos para data centers remotos, Cloud Data refere-se a um ecossistema integrado de serviços gerenciados, no qual a infraestrutura é abstraída e o foco desloca-se para governança, escalabilidade, análise e valor de negócio.

Historicamente, arquiteturas de dados eram baseadas em sistemas monolíticos rigidamente acoplados, onde computação e armazenamento cresciam juntos, resultando em baixa elasticidade e alto custo. A computação em nuvem rompe esse paradigma introduzindo a separação entre computação e armazenamento, o princípio fundamental das arquiteturas modernas de dados.

Nesse modelo, dados são persistidos de forma durável e econômica em armazenamento de objetos (object storage), enquanto a computação é provisionada sob demanda, de forma efêmera, permitindo escalar processamento sem replicar dados. Clusters e motores analíticos podem ser criados por minutos para executar cargas intensivas e desligados em seguida, viabilizando elasticidade e otimização de custos.

Atualmente, o mercado de Cloud Data é dominado por três grandes provedores – Amazon Web Services (AWS), Google Cloud Platform (GCP) e Microsoft Azure – cada um com filosofias arquiteturais distintas e um amplo leque de serviços gerenciados. Apesar das diferenças, todos convergem na ideia de tirar dos engenheiros de dados a carga de gerenciar infraestrutura de baixo nível, permitindo foco em arquiteturas lógicas e requisitos de negócio.

Gerações de Arquitetura de Dados

A evolução arquitetural do gerenciamento de dados pode ser compreendida em três gerações principais, cada uma surgindo para superar limitações da anterior:

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

GERAÇÃO	DESCRIÇÃO	CARACTERÍSTICAS	LIMITAÇÕES
Data Warehouse	Ambientes de armazenamento de dados estruturados, altamente otimizados para consultas SQL e Business Intelligence, geralmente baseados em bancos de dados relacionais ou appliances proprietários.	• Forte consistência e confiabilidade • Alta performance para consultas complexas • Modelo *schema-on-write* • Ideal para relatórios e BI corporativo	• Baixa flexibilidade para dados semi e não estruturados • Alto custo de escalabilidade • Escalabilidade vertical ou via appliances • Planejamento rígido de capacidade e subutilização de recursos
Data Lake	Repositório centralizado para armazenamento de grandes volumes de dados estruturados, semi-estruturados e não estruturados, geralmente baseado em sistemas de arquivos distribuídos ou object storage.	• Alta escalabilidade horizontal • Baixo custo de armazenamento • Suporte a múltiplos formatos de dados • Modelo *schema-on-read* • Adequado para analytics exploratório e ciência de dados	• Governança e qualidade mais complexas • Ausência de controles transacionais nativos • Risco de se tornar um *Data Swamp* sem boas práticas • Performance inconsistente para BI tradicional
Lakehouse	Arquitetura que combina a flexibilidade e economia do Data Lake com as garantias e a performance do Data Warehouse, utilizando formatos abertos e camadas de gerenciamento transacional.	• Dados em formatos abertos (Parquet, ORC, Avro) • Suporte a transações ACID • *Time travel* e versionamento de dados • Updates e deletes eficientes • Acesso unificado para BI, Analytics e Machine Learning	• Maior complexidade conceitual • Dependência de camadas adicionais de gerenciamento • Exige maior maturidade arquitetural e de governança

Tabela 1 – Gerações de arquitetura de dados
Fonte: elaborado pelo autor (2026)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Para organizar os dados dentro de um Lakehouse (ou mesmo de um data lake tradicional) adota-se frequentemente a Medallion Architecture – uma divisão lógica em camadas Bronze, Silver e Gold que já conhecemos anteriormente e representam estágios crescentes de qualidade e estrutura. Essa progressão incremental melhora a qualidade e a organização a cada etapa, facilitando governança e reuso dos dados.

Para ficar fácil na memória, uma arquitetura de Data Warehouse tradicional lida bem apenas com dados estruturados, fornecendo consistência e desempenho SQL altos, mas com pouca elasticidade e alto custo por escala limitada. O Data Lake expande para todos os tipos de dados com baixo custo, porém sacrificando as garantias transacionais e exigindo esforço para evitar desorganização. O Lakehouse, por sua vez, busca entregar confiabilidade e governança equivalentes a um warehouse diretamente sobre dados no lake, unificando cenários analíticos e de ciência de dados em uma única plataforma.

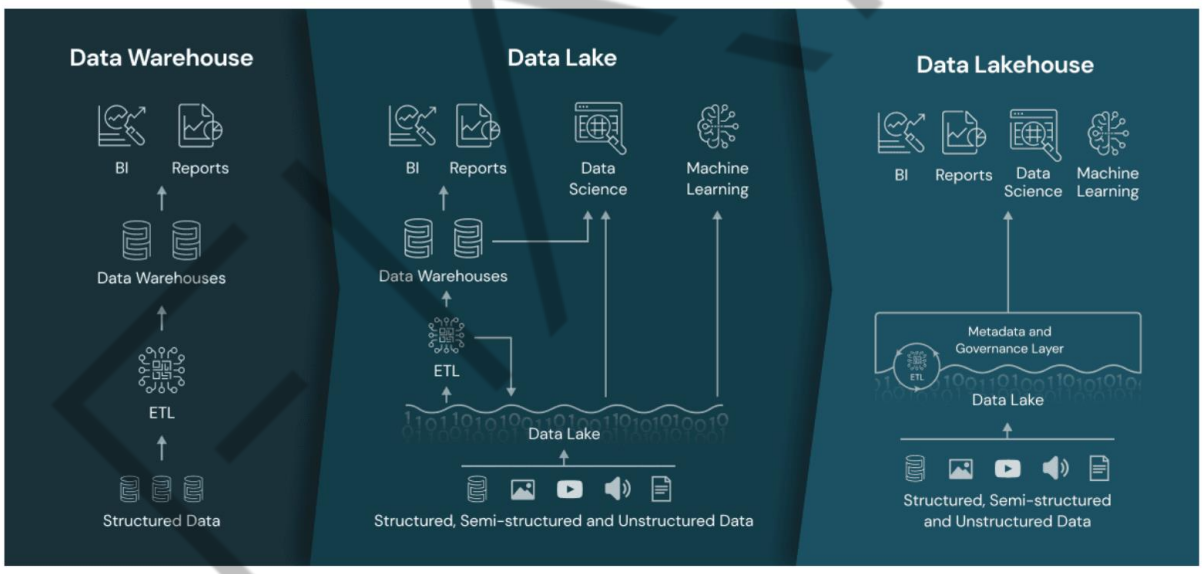


Figura 1 - Exemplificação das gerações de arquitetura de dados
Fonte: Databricks - Data lakehouse (2025)

Vantagens Estratégicas do Cloud Data

Eficiência de Custos e Elasticidade

Em ambientes de Cloud Data, o modelo *pay-as-you-go* permite pagar apenas pelos recursos utilizados, eliminando a necessidade de infraestrutura superdimensionada. A elasticidade da nuvem possibilita escalar computação e armazenamento de forma independente, ativando alto poder de processamento

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

apenas quando necessário e reduzindo custos em períodos de ociosidade. Essa flexibilidade diminui desperdícios, viabiliza estratégias como o uso de instâncias spot e permite escalar em segundos, pagando somente pelo tempo efetivo de uso.

Isolamento de Performance

A separação entre armazenamento e computação permite que diferentes workloads utilizem os mesmos dados simultaneamente, sem competir por recursos. Com isso, equipes de BI, engenharia de dados, ciência de dados e Machine Learning podem operar de forma isolada, cada uma com seu próprio poder computacional, garantindo escalabilidade independente e evitando impactos de performance entre aplicações. Essa arquitetura aumenta a confiabilidade e mantém desempenho consistente mesmo em cenários de alta concorrência.

Escalabilidade e Alta Disponibilidade

Nas nuvens públicas, escalar recursos deixou de ser um obstáculo: é possível expandir serviços e instâncias em minutos, acompanhando o crescimento de dados e usuários quase em tempo real. Além disso, os serviços de nuvem oferecem altíssima durabilidade e disponibilidade, com dados replicados automaticamente e infraestrutura tolerante a falhas, por exemplo, o Amazon S3 garante durabilidade de 99,999999999% (11 noves) dos objetos armazenados, replicando dados automaticamente em múltiplas zonas. O resultado são arquiteturas de dados mais escaláveis, resilientes e confiáveis, acessíveis sob demanda mesmo para empresas de menor porte.

Camada de Armazenamento: Object Storage como Fundamento

O armazenamento de objetos é a base das arquiteturas Cloud Data. Diferente de armazenamento em sistema de arquivos (NAS) ou em blocos (SAN), onde dados ficam em diretórios hierárquicos ou volumes fixos, o object storage gerencia dados como objetos independentes, cada objeto possui um identificador único global e metadados descritivos ricos. Essa abordagem traz escala praticamente ilimitada e simplicidade de acesso (via APIs REST), tornando-a ideal para data lakes na nuvem.

Todos os grandes provedores oferecem object storage altamente durável e escalável: o Amazon S3, o Azure Blob Storage (e ADLS Gen2) e o Google Cloud Storage (GCS). Embora semelhantes no conceito, cada um possui características evolutivas importantes:

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Amazon S3

O Amazon S3 consolidou-se como padrão de object storage e evoluiu ao oferecer consistência forte de leitura após escrita, simplificando pipelines de dados. Com múltiplas classes de armazenamento, permite alinhar custo e frequência de acesso ao longo do ciclo de vida dos dados. Sua alta durabilidade, grande throughput e recursos como leitura otimizada e integração nativa de metadados fazem do S3 uma base robusta para arquiteturas modernas de dados.

Azure Data Lake Storage Gen2 (ADLS Gen2)

O ADLS Gen2 estende o Azure Blob Storage para Big Data ao oferecer namespace hierárquico, permitindo operações eficientes sobre diretórios e reduzindo latência em workloads analíticos. O suporte a ACLs no estilo POSIX, integrado ao Azure Active Directory, garante controle de acesso granular e governança diretamente no storage. Essas capacidades tornam o ADLS Gen2 ideal para cenários corporativos, desde que o uso do namespace hierárquico seja adequado ao tipo de workload.

Google Cloud Storage

O Google Cloud Storage oferece simplicidade e desempenho consistente, com acesso imediato aos dados em todas as classes de armazenamento, inclusive as de arquivamento, facilitando estratégias de tiering e consultas históricas sob demanda. Complementando essa abordagem, o BigQuery atua como um data warehouse serverless totalmente gerenciado, abstraindo a infraestrutura e permitindo análises em larga escala via SQL com alta agilidade e produtividade para times de analytics e data science.

Em resumo, o GCP foca em entregar experiência unificada e de baixo atrito, enquanto AWS e Azure tendem a oferecer maior controle e variedade de ferramentas (com possível complexidade extra).

Camada de Computação e Analytics

Acima do armazenamento bruto residem os motores de processamento responsáveis por transformar dados e extrair insights. Cada provedor de nuvem tem

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

uma abordagem distinta para essa camada, refletindo também estratégias de mercado e perfis de usuários alvo:

AWS Abordagem Modular

A AWS adota uma abordagem modular, oferecendo serviços especializados que podem ser combinados conforme a necessidade, como Glue para ETL, Athena para consultas SQL serverless, EMR para processamento distribuído e Redshift para data warehousing. Essa estratégia garante alta flexibilidade e permite montar arquiteturas sob medida, com integração crescente entre os serviços e separação de armazenamento e computação. Em contrapartida, essa liberdade vem acompanhada de maior complexidade operacional e curva de aprendizado, exigindo mais esforço de orquestração e governança.

Azure – Abordagem de Convergência (Synapse)

A Microsoft apostou na unificação com o Azure Synapse Analytics, que reúne em um único ambiente data warehouse, big data e integração de dados. A plataforma permite alternar entre SQL, Spark e pipelines ETL compartilhando o mesmo data lake e governança, com forte integração ao ecossistema Microsoft. Essa abordagem aumenta a produtividade em cenários enterprise, oferecendo uma experiência de ponta a ponta, ainda que internamente utilize motores distintos conforme o tipo de workload.

GCP – Abordagem Serverless e Autônoma

O Google Cloud destaca-se pela abstração total da infraestrutura, com o BigQuery como principal serviço analítico serverless e altamente escalável. Os recursos são alocados automaticamente conforme as consultas, garantindo alto desempenho e concorrência com mínima gestão operacional. Em comparação, enquanto AWS e Azure oferecem mais controle e modularidade, o GCP prioriza simplicidade, automação e eficiência na operação.

BigQuery (GCP)

O BigQuery exemplifica o modelo de data warehouse totalmente gerenciado e serverless, com separação entre armazenamento e computação, permitindo escalar

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

consultas sob demanda e pagar apenas pelos dados processados. Recursos como particionamento, clusterização, cache e reclustering automático mantêm a performance mesmo em grandes volumes, enquanto integrações com dados externos e inteligência artificial ampliam seus casos de uso. Ao eliminar a gestão de infraestrutura, o BigQuery permite rápida experimentação e escala por equipes pequenas, exigindo que a otimização de custo e desempenho seja feita principalmente por meio de boas práticas de modelagem e uso eficiente dos recursos disponíveis.

Azure Synapse Analytics

O Azure Synapse é uma plataforma analítica unificada que combina SQL, Spark e integração de dados em um único workspace. Ele permite executar consultas SQL serverless sobre dados no Data Lake, usar pools dedicados para workloads previsíveis e rodar jobs Spark integrados ao mesmo ambiente, compartilhando dados entre essas camadas de forma simples. Sua principal vantagem está na produtividade e integração, reunindo ingestão, transformação, analytics e governança em uma única solução, com flexibilidade de custos e controle operacional, especialmente voltada a cenários corporativos.

AWS - Portfólio Modular de Serviços Analíticos

Na AWS, não há um “Synapse” ou “BigQuery” único, em vez disso, há um ecossistema de serviços analíticos que podem ser combinados conforme a necessidade. Alguns componentes notáveis:

- **Amazon Athena:** serviço de SQL serverless que permite executar queries ANSI SQL diretamente em arquivos no S3 (formatos Parquet, ORC, CSV, JSON, etc.). Baseado no Presto (Trino), o Athena é ideal para análises ad-hoc em dados do data lake, sem precisar carregar esses dados em um banco. O usuário paga por TB lido (também cerca de $5 por TB), então otimizar partições e colunas dos arquivos é importante. Athena se integra ao Glue Data Catalog para conhecer os schemas das tabelas no S3, funcionando como um “virtual warehouse” simples para BI.
- **AWS Glue:** serviço gerenciado de ETL que executa jobs Spark de forma serverless, simplificando a criação e a orquestração de pipelines batch e streaming sem a necessidade de gerenciar infraestrutura. Ele se destaca

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

pelo Glue Data Catalog, que centraliza metadados e viabiliza governança e integração com serviços como Athena e Redshift Spectrum. Com recursos como geração automática de código, suporte a streaming e ferramentas visuais de preparação de dados, o Glue atua como uma solução versátil e integrada para ETL no ecossistema AWS.

- **Amazon EMR:** indicado para quem busca maior controle sobre clusters Hadoop e Spark, permitindo configurar instâncias, dimensionamento e softwares conforme o workload. Ele atende bem cenários complexos ou contínuos, pode reduzir custos com uso de instâncias spot e oferece múltiplos engines de processamento, além do modo EMR Serverless. É comum em arquiteturas AWS quando há expertise prévia em Hadoop ou quando manter clusters ativos se mostra mais econômico para grandes pipelines de processamento.
- **Amazon Redshift:** é a solução de data warehouse MPP da AWS, que evoluiu de clusters fixos para modelos mais flexíveis com separação entre armazenamento e computação, como o RA3 e o Redshift Serverless. Ele permite consultar dados no próprio warehouse ou diretamente no S3 via Redshift Spectrum, integrando lake e warehouse. Fortemente integrado ao ecossistema AWS e familiar para equipes SQL, o Redshift oferece alto desempenho e consistência para workloads analíticos, embora exija maior atenção a tuning e distribuição de dados em comparação a soluções totalmente autogerenciadas.
- **Outros Serviços:** a AWS ainda possui o Amazon QuickSight (ferramenta BI serverless integrada, para dashboards), o AWS SageMaker (plataforma de ML gerenciada, que lida bem com dados no S3/Redshift), o Amazon Kinesis (para ingestão de streaming de eventos em tempo real, com variantes Data Streams, Data Firehose, etc.), e serviços de orquestração como o AWS Step Functions ou Managed Workflows for Apache Airflow (MWAA) para coordenar pipelines multi-serviço.

Em resumo, a camada de computação na AWS é composta por Lego pieces: Athena para SQL on-demand, Glue/EMR para ETL e processamento, Redshift para data warehousing clássico, e outros componentes plugáveis. Isso dá poder de ajustar a arquitetura exatamente às necessidades, mas exige do arquiteto uma boa visão do

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

trade-off de cada serviço e como integrá-los (ex: usar Glue jobs para preparar dados que serão consumidos no Redshift ou Athena; ou descarregar parte das consultas do Redshift para Spectrum no S3 quando dados crescerem muito, etc.). A AWS fornece padrões de referência (arquiteturas Lake House AWS) que guiam essas integrações, muitas vezes usando o S3 como ponto central (data lake) cercado por esses motores especializados.

Estruturas Arquiteturais Modernas

A maturidade do ecossistema Cloud Data impulsionou também novas abordagens arquiteturais em nível organizacional e sistêmico. Três conceitos que ganharam destaque nos últimos anos são o Lakehouse, o Data Mesh e o Data Fabric. Eles não se excluem mutuamente, muitas vezes, coexistem e se complementam dentro de grandes organizações, mas convém entender seus focos:

- **Lakehouse:** representa uma evolução arquitetural que une data lakes e data warehouses ao adotar formatos abertos com metadados e garantias ACID. Essa abordagem permite aplicar esquemas medalhão, time travel e suportar workloads analíticos, preditivos e de streaming sobre uma única fonte de dados, reduzindo duplicações e custos. Impulsionado por ferramentas modernas e incorporado gradualmente por soluções tradicionais, o Lakehouse se consolida como um padrão arquitetural, cujo uso depende das necessidades da empresa e da maturidade desejada na convergência entre BI e Data Science.
- **Data Mesh:** introduzido por Zhamak Dehghani em 2019, propõe uma mudança organizacional na engenharia de dados ao descentralizar a responsabilidade dos dados por domínio de negócio. Nesse modelo, cada área passa a tratar seus dados como produtos, com qualidade, documentação e SLAs, apoiada por uma plataforma self-service e governança federada. O objetivo é eliminar gargalos de times centralizados, aumentar a autonomia dos domínios e escalar a produção e o uso de dados de forma alinhada ao negócio, sendo a adoção muito mais um desafio cultural e de processos do que apenas tecnológico.
- **Data Fabric:** é uma abordagem arquitetural e tecnológica que busca unificar o acesso a dados distribuídos por meio de uma camada lógica sobreposta

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

às fontes existentes. Diferente do Data Mesh, que foca na organização, o Fabric enfatiza virtualização, metadados, automação e governança para permitir consultas e integrações transparentes entre sistemas heterogêneos. Essa abordagem é especialmente útil em ambientes com muitos silos, legados ou multi-cloud, ao simplificar o acesso e o consumo de dados sem exigir sua consolidação física em um único repositório.

O Data Fabric não substitui Data Lakes ou Data Mesh, mas atua de forma complementar, oferecendo uma camada de acesso unificado sobre dados distribuídos. Ele permite integrar domínios de um Data Mesh ou conviver com arquiteturas Lakehouse e sistemas legados sem migração imediata, simplificando o consumo de dados. Grandes fornecedores têm adotado essa abordagem ao integrar integração, catálogo, qualidade e segurança em soluções únicas.

Exemplos de Arquitetura ETL em cada Provedor

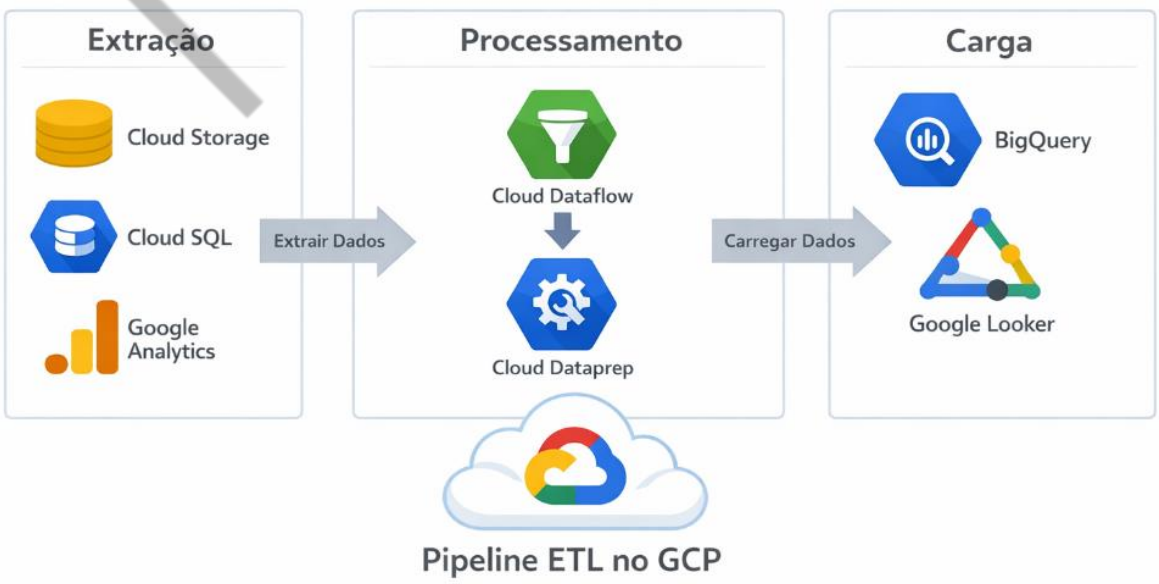
Para concretizar os conceitos, vejamos como se parece uma pipeline de dados em nuvem mapeada nos serviços de AWS, GCP e Azure. Apesar das implementações variarem, notamos uma estrutura comum.

Camada da Arquitetura	AWS	GCP	AZURE
Ingestão Batch	AWS DMS, AWS Glue Crawlers, AWS Data Pipeline	Cloud Datastream, Storage Transfer Service	Azure Data Factory, Azure Database Migration Service
Ingestão Streaming / Eventos	Amazon Kinesis Data Streams, Amazon MSK (Kafka), AWS Lambda	Pub/Sub, Dataflow (streaming)	Event Hubs, Azure Stream Analytics
Raw/ Bronze (Data Lake)	Amazon S3	Google Cloud Storage (GCS)	Azure Blob Storage / ADLS Gen2
Catálogo de dados	AWS Glue Data Catalog	Data Catalog	Azure Purview (Microsoft Purview)
Governança de dados	AWS Lake Formation	Dataplex	Microsoft Purview

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Processamento Batch	AWS Glue Jobs (Spark), Amazon EMR	Dataflow (Batch), Dataproc (Spark)	Azure Synapse Spark, Azure Databricks
Processamento Streaming	Kinesis Data Analytics (Flink), Spark Streaming (EMR)	Dataflow (Apache Beam)	Azure Stream Analytics, Spark Structured Streaming
Silver/Gold (Lakehouse)	S3 + Apache Hudi / Delta Lake / Iceberg	BigQuery + BigLake / GCS + Delta/Iceberg	ADLS + Delta Lake (Databricks)
DW / Consulta SQL	Amazon Athena, Amazon Redshift (Spectrum)	BigQuery	Azure Synapse Analytics (Serverless / Dedicated)
BI / Visualização	Amazon QuickSight	Looker / Looker Studio	Power BI
Machine Learning	Amazon SageMaker	Vertex AI, BigQuery ML	Azure Machine Learning
Orquestração	MWAA (Airflow), Step Functions, EventBridge	Cloud Composer (Airflow), Workflows, Cloud Scheduler	Azure Data Factory, Azure Logic Apps
Observabilidade / Monitoramento	CloudWatch, AWS CloudTrail	Cloud Monitoring, Cloud Logging	Azure Monitor, Log Analytics

Tabela 2 – Tecnologias para criar a esteira de pipeline
Fonte: elaborado pelo autor (2026)



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Figura 2 - Exemplificação do desenho de uma arquitetura para pipeline ETL utilizando GCP
Fonte: Criado pelo autor utilizando a ferramenta Canva (2026)

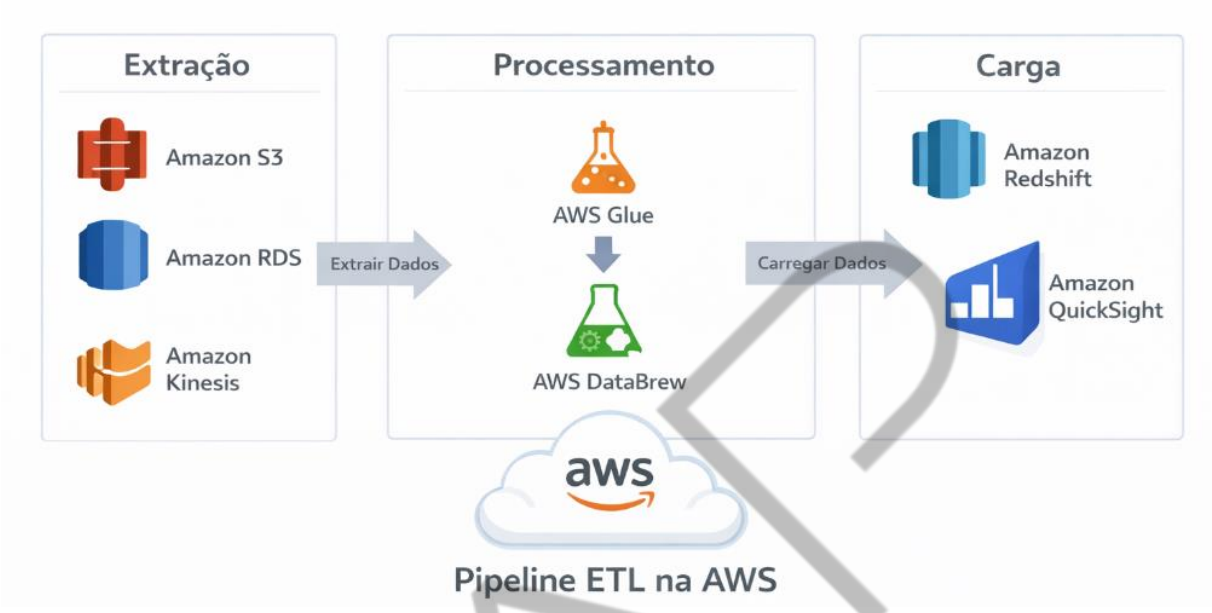


Figura 3 - Exemplificação do desenho de uma arquitetura para pipeline ETL utilizando AWS
Fonte: Criado pelo autor utilizando a ferramenta Canva (2026)

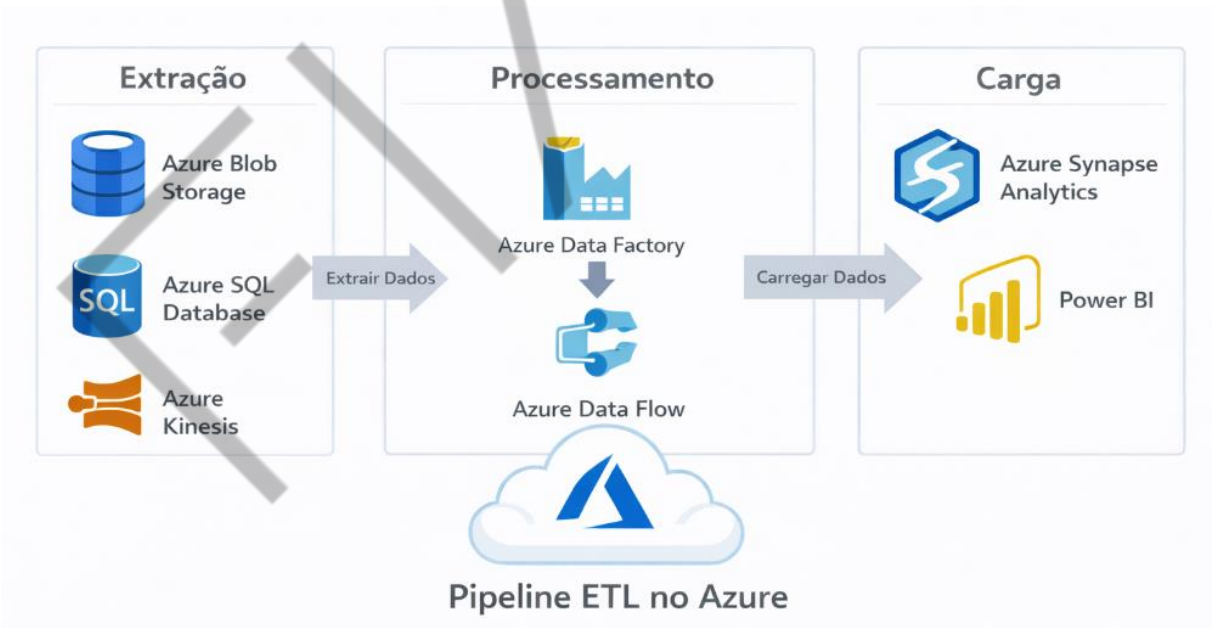


Figura 4 - Exemplificação do desenho de uma arquitetura para pipeline ETL utilizando Azure
Fonte: Criado pelo autor utilizando a ferramenta Canva (2026)

Em última análise, os três provedores suportam plenamente arquiteturas modernas de dados, cabendo aos profissionais selecionar os componentes que melhor se encaixam às preferências e restrições do projeto, sabendo que os padrões

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

de arquitetura são transferíveis, quem entende a fundo uma pipeline em AWS conseguirá mapear facilmente conceitos equivalentes em GCP ou Azure.

Custos, Riscos e Decisões Arquiteturais

Embora a nuvem ofereça enorme flexibilidade e potencial de inovação rápida, ela também introduz riscos, especialmente financeiros, se a arquitetura não for cuidadosamente planejada com custos em mente. Alguns pontos de atenção incluem:

- **Custos de Transferência de Dados (Egress):** a movimentação de dados na nuvem, especialmente entre regiões ou para fora do provedor, pode gerar custos elevados de egress que muitas vezes passam despercebidos. Transferências automáticas, como replicações e backups, podem impactar significativamente a fatura. Por isso, arquiteturas multi-regionais ou multi-cloud devem ser desenhadas para minimizar egress, mantendo o processamento próximo aos dados e monitorando ativamente fluxos de transferência para evitar surpresas de custo ao longo do tempo.
- **Consultas Mal Otimizadas e Custos de Computação:** em data warehouses serverless, o custo está diretamente ligado aos dados lidos ou processados, tornando consultas sem filtros ou sem uso de partições potencialmente muito caras. Em ambientes provisionados, consultas ineficientes aumentam o consumo de CPU e, consequentemente, os custos. Por isso, uma boa modelagem com particionamento, indexação ou clusterização, aliada a limites, alertas e monitoramento contínuo das consultas, é essencial para controlar gastos e evitar surpresas financeiras.
- **Dimensionamento e Over-Provisioning:** na nuvem podemos escalar facilmente, mas isso também facilita gastar demais se não formos diligentes. Um risco comum é manter recursos maiores do que o necessário por esquecimento ou por segurança exagerada. Exemplos: manter um cluster de 10 nós no fim de semana quando ninguém usa; alocar armazenamento provisionado de DW bem acima do uso real; não desligar clusters de teste. A cultura do *auto-scaling* e *auto-shutdown* deve ser incorporada em cada arquitetura. Muitos serviços gerenciados já oferecem *schedules* ou *idle timeout* – configurá-los evita surpresas.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

- **Escolha inadequada de serviços ou classes:** decisões arquiteturais inadequadas podem elevar significativamente os custos em nuvem, como usar bancos relacionais para dados históricos ou manter informações pouco acessadas em classes de armazenamento caras. Conhecer bem as opções de storage e processamento, aplicar políticas de lifecycle e escolher a ferramenta adequada para cada tipo de workload são ações essenciais para evitar desperdícios. Por isso, arquitetos de dados precisam incorporar práticas de FinOps, monitorando custos por pipeline e ajustando continuamente a arquitetura para maximizar o retorno sobre o investimento.
- **Riscos de Complexidade e Operação:** embora a nuvem facilite a construção rápida de sistemas complexos, arquiteturas com muitos componentes aumentam o risco operacional e os pontos de falha. Priorizar simplicidade e serviços gerenciados reduz esforço de operação, monitoramento e manutenção. Ao mesmo tempo, é importante equilibrar agilidade e lock-in tecnológico, avaliando o custo total e a estratégia de longo prazo antes de escolher entre soluções proprietárias ou mais flexíveis.

Em suma, arquitetar em Cloud Data exige um balanço entre desempenho, governança e eficiência econômica. As arquiteturas bem-sucedidas incorporam considerações de custo desde o desenho inicial, em vez de tratar finanças como reflexão tardia. Há até práticas de “arquitetura orientada a custo”, ex.: projetar pipelines pensando qual o custo por TB ingerido e transformado, escolhendo design de dados que minimize movimentação e duplicação. Com monitoramento e ajustes contínuos, é possível usufruir da escala e poder da nuvem sem estourar o orçamento, entregando valor de negócio de forma sustentável.

CONCLUSÃO

O advento do Cloud Data consolidou-se como base das arquiteturas modernas de dados, deslocando o foco da engenharia de dados de tarefas de infraestrutura (provisionar servidores, ajustar discos, gerenciar clusters manualmente) para decisões arquiteturais de alto nível e alinhamento ao negócio. Nesta transformação, a separação entre computação e armazenamento emergiu como princípio-chave, permitindo escalabilidade elástica e isolada de componentes, e padrões como o

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Lakehouse habilitaram novos patamares de unificação entre dados operacionais, analíticos e de ciência de dados.

Um profissional de dados atual precisa dominar não apenas ferramentas específicas, mas principalmente os *trade-offs* envolvidos em cada escolha arquitetural: por que usar um fluxo de streaming vs batch, quando armazenar dados em Parquet no lake vs inserir num warehouse, qual combinação de serviços equilibra melhor custo e performance para determinado caso, como garantir qualidade e segurança ao mesmo tempo em que se democratiza acesso aos dados, entre outros desafios. Em outras palavras, o engenheiro de dados na era do Cloud Data é também um arquiteto, navegando pelas ofertas de nuvem e compondo soluções modulares que melhor atendam às necessidades da organização.

Este módulo abordou os pilares de Cloud Data com ênfase prática nas arquiteturas ETL em nuvem. Vimos que, independentemente do provedor, existem conceitos comuns (ETL/ELT, bronze-prata-ouro, stream vs batch, data lake, data warehouse, etc.) e vantagens significativas a explorar (elasticidade, isolamento, serviços gerenciados). Ao mesmo tempo, ressaltamos cuidados para evitar armadilhas de custos e complexidade excessiva.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

MERCADO, CASES E TENDÊNCIAS

Entre as principais tendências do mercado, destaca-se o crescimento do Analytics Engineering, que aproxima cientistas de dados e analistas da camada de transformação, utilizando práticas de engenharia de software aplicadas a SQL. Ferramentas como DBT popularizaram conceitos como versionamento, testes automatizados e modularização das transformações, reforçando a adoção de pipelines ELT em ambientes de nuvem. Essa abordagem tem se mostrado essencial em arquiteturas modernas baseadas em Data Lake e Lakehouse.

Do ponto de vista de mercado, observa-se também uma forte convergência entre Cloud Data e Inteligência Artificial. Provedores de nuvem vêm posicionando seus serviços analíticos como base para aplicações de IA generativa, reforçando a importância de pipelines escaláveis, dados bem organizados e governança desde o desenho da arquitetura.

Indicação de material para consumo:

“Google - The key pillars of building a modern data platform - Youtube:

https://www.youtube.com/watch?v=UwKXKs0CCt8

“AWS Skill Builder – Aprendizado em Cloud e Dados”

A plataforma oficial de treinamento da AWS, o AWS Skill Builder oferece diversas trilhas de aprendizagem voltadas à engenharia de dados, arquiteturas serverless, orquestração de pipelines, analytics e serviços de armazenamento. Disponível em: https://skillbuilder.aws/

“Google Cloud Skill Boosts”

O Google Cloud Skill Boosts (antigo Qwiklabs/Cloud Skills Boost) oferece laboratórios práticos e trilhas de aprendizagem para desenvolvimento em Google Cloud, incluindo tópicos de ingestão de dados, BigQuery, Dataflow, Pub/Sub, orquestração e pipelines ELT. Muitos badges podem ser obtidos gratuitamente por programas de créditos iniciais.

Disponível em: https://www.skills.google/catalog?skill-badge

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você compreendeu como o conceito de Cloud Data vai além da simples migração de ambientes on-premises para a nuvem, representando uma mudança estrutural na forma como dados são armazenados, processados e consumidos. Foram discutidos os fundamentos das arquiteturas modernas, baseadas na separação entre computação e armazenamento, que permitem maior elasticidade, escalabilidade e otimização de custos.

Você explorou como pipelines de dados evoluem na nuvem, passando de modelos rígidos e batch para arquiteturas mais flexíveis, que podem combinar processamento em batch, streaming ou modelos híbridos, sempre orientados às necessidades reais do negócio. Essa análise mostrou que a modernização de pipelines é tanto uma decisão técnica quanto estratégica.

Ao longo do conteúdo, você foi guiado(a) por um processo estruturado de tomada de decisão arquitetural, aprendendo a definir estratégia de migração, organização e retenção de dados, modelo de ingestão, orquestração, governança, segurança e observabilidade antes mesmo de escolher tecnologias ou provedores de nuvem.

Na parte prática, viu como essas decisões se materializam em arquiteturas de Cloud Data, com exemplos de tecnologias oferecidas por AWS, Google Cloud e Azure.

Mapa Mental

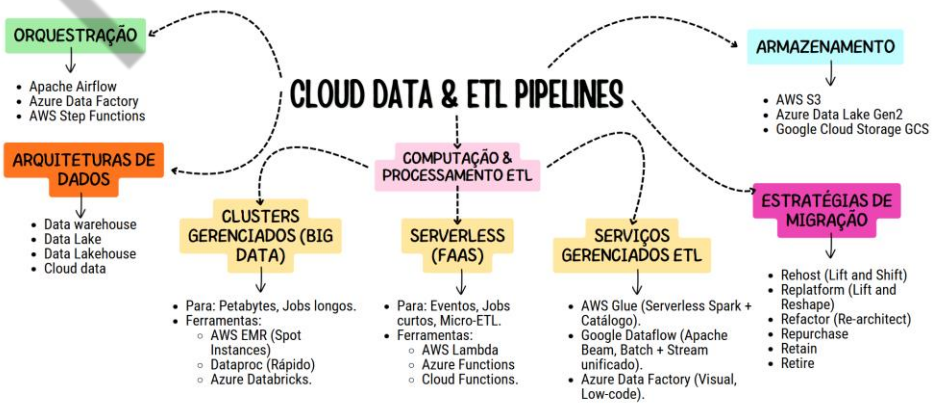


Figura 4 - Mapa mental com o conteúdo abordado
Fonte: Elaborado pelo autor utilizando a ferramenta Canva IA (2026)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

REFERÊNCIAS

AWS Documentation. Disponível em: https://docs.aws.amazon.com/. Acesso em: 25 mar. 2026.

AWS Whitepaper. *What is a modern data architecture?*. Acesso em: 25 mar. 2026.

Google Cloud Documentation. Disponível em: https://docs.cloud.google.com/docs?hl=pt-br. Acesso em: 25 mar. 2026.

KLEPPMANN, Martin. **Designing Data-Intensive Applications**. Sebastopol: O'Reilly Media, 2017.

Microsoft Azure Documentation. Disponível em: https://learn.microsoft.com/en-us/azure/. Acesso em: 25 mar. 2026.

REIS, Joe; HOUSLEY, Matt. **Fundamentals of Data Engineering: Plan and Build Robust Data Systems**. Sebastopol: O'Reilly Media, 2022.

SAKHATSKY, Michael. **Modern Data Architectures Explained: A Critical Examination of Modern Strategies and Their Impacts**. Medium. Disponível em: https://medium.com/@msakhatsky/modern-data-architectures-explained-a9a4e0c8d8ed. Acesso em: 25 mar. 2026.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

PALAVRAS-CHAVE

Cloud Data. Arquitetura de dados. Estratégia de migração.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com