

AI SCIENTIST

FASE 2 | AULA 04 -

FINOPS EM AMBIENTE CLOUD

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SUMÁRIO

O QUE VEM POR AÍ? 3

HANDS ON 4

SAIBA MAIS 6

MERCADO, CASES E TENDÊNCIAS 22

O QUE VOCÊ VIU NESTA AULA? 23

REFERÊNCIAS 25

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VEM POR AÍ?

FinOps (Financial Operations) surgiu como uma disciplina que integra princípios de gestão financeira às operações e engenharia de nuvem. Em termos simples, trata-se de aproximar as equipes de finanças e tecnologia para controlar melhor os custos de cloud, promovendo responsabilidade compartilhada pelos gastos e maximizando o ROI (retorno sobre investimento) das soluções em nuvem. No contexto de arquiteturas de dados em nuvem, o FinOps ganha relevância adicional: à medida que organizações expandem pipelines de dados, data lakes e iniciativas de Big Data, os custos de computação e armazenamento podem escalar de forma imprevisível. A promessa do FinOps é garantir inovações contínuas em dados sem estourar o orçamento, fornecendo visibilidade e governança financeira constantes.

A transição para nuvem trouxe uma mudança de mentalidade de um modelo CAPEX (grandes investimentos de capital em hardware próprio) para OPEX (custos operacionais variáveis conforme o uso). Nesse novo paradigma, pagar somente pelo uso traz agilidade, mas também pode gerar “sustos” na fatura se não houver controle. Diferentemente do data center tradicional – onde custos eram fixos e previsíveis (pois o equipamento era comprado antecipadamente) – na nuvem cada consulta de dados, cada hora de instância e cada gigabyte transferido aparece na conta. Isso exige que engenheiros e cientistas de dados desenvolvam um modelo mental orientado a custos, incorporando considerações financeiras já no design de sistemas de dados. Em outras palavras, eficiência de custo torna-se tão importante quanto desempenho e escalabilidade.

Vamos explorar a aplicação do framework FinOps no contexto de pipelines ETL, integração em tempo real com sistemas como Apache Kafka e gerenciamento de grandes volumes de dados em nuvem.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

HANDS ON

Laboratório Teórico: Pipeline ETL com Validação de Qualidade

Você faz parte de um time e foi convidado a participar de um comitê de adoção de FinOps em uma empresa que está expandindo seus investimentos em IA e análise preditiva na nuvem. A empresa deseja adotar práticas modernas de controle de custos, porém ainda não possui processos maduros de governança financeira na infraestrutura de dados.

Sua missão será avaliar a maturidade atual da organização, identificar riscos ocultos, propor estratégias de integração de práticas FinOps com MLOps e sugerir ferramentas que viabilizem essa governança. Além disso, deverá justificar a escolha de métodos e tecnologias, embasando sua proposta com fundamentos do conteúdo estudado e pesquisas complementares.

Etapas do Laboratório

1. **Diagnóstico Inicial – "Onde estamos":** simule o preenchimento de uma autoavaliação de maturidade FinOps (disponível em: https://www.finops.org/wg/finops-assessment/) com base em um cenário fictício (ou inspirado em uma empresa real conhecida). Registre os pontos fortes, ausências e oportunidades de melhoria.

2. **Mapeamento de riscos financeiros ocultos:** liste ao menos 3 fontes potenciais de desperdício financeiro em workloads de dados (ETL, ML, armazenamento, streaming), considerando formatos, transferência e uso de instâncias não otimizadas.

3. **Integração com MLOps e Cultura DevFinOps:** descreva uma estratégia de integração de práticas FinOps a um ciclo de Machine Learning típico. Inclua etapas como: treinamento com GPU, ambientes interativos, versionamento de modelos, tagging por ID de experimento, entre outros. Considere o papel do time financeiro no processo.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

4. **Proposta Final de Estratégia:** com base nas etapas anteriores, redija uma proposta de com recomendações para adoção de FinOps na organização analisada. Inclua sugestões técnicas, ferramentas, estratégias de tagging e ações de curto prazo (quick wins).

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

SAIBA MAIS

FinOps para Ambiente Cloud

A transição das arquiteturas de dados corporativas para ambientes nativos em nuvem alterou fundamentalmente a economia da ciência e da engenharia de dados. Se os estágios iniciais da adoção da nuvem foram caracterizados por uma busca incessante por escalabilidade bruta e agilidade, o paradigma atual exige responsabilidade financeira e a otimização sistemática do valor de negócio. FinOps, um portmanteau de "Finance" e "DevOps", emergiu como um framework operacional e uma prática cultural crítica que facilita a colaboração entre as equipes de engenharia, finanças e negócios para maximizar o retorno dos investimentos em nuvem.

O Ciclo de Vida FinOps nos Pipelines de Dados

A prática de FinOps é estruturada em três fases iterativas: Informar, Otimizar e Operar.

Na fase de Informação, o objetivo é dar visibilidade clara sobre custos, uso e eficiência da nuvem, viabilizando alocação precisa por meio de tagging, hierarquias de contas e automação, com destaque para padrões como o FOCUS, que unificam dados de faturamento entre provedores.

Na fase de Otimização, o foco é reduzir custos sem perder performance, atuando tanto no uso dos recursos, por meio de rightsizing e ajustes de retenção, quanto nas taxas, aproveitando modelos de desconto por compromisso como RIs, Savings Plans e CUDs.

Na fase de Operação, o FinOps é institucionalizado com governança, políticas e mudança cultural, incentivando engenheiros e cientistas de dados a tratar custo como métrica de eficiência, apoiados por automação e feedback contínuo para manter o controle financeiro em ambientes elásticos.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

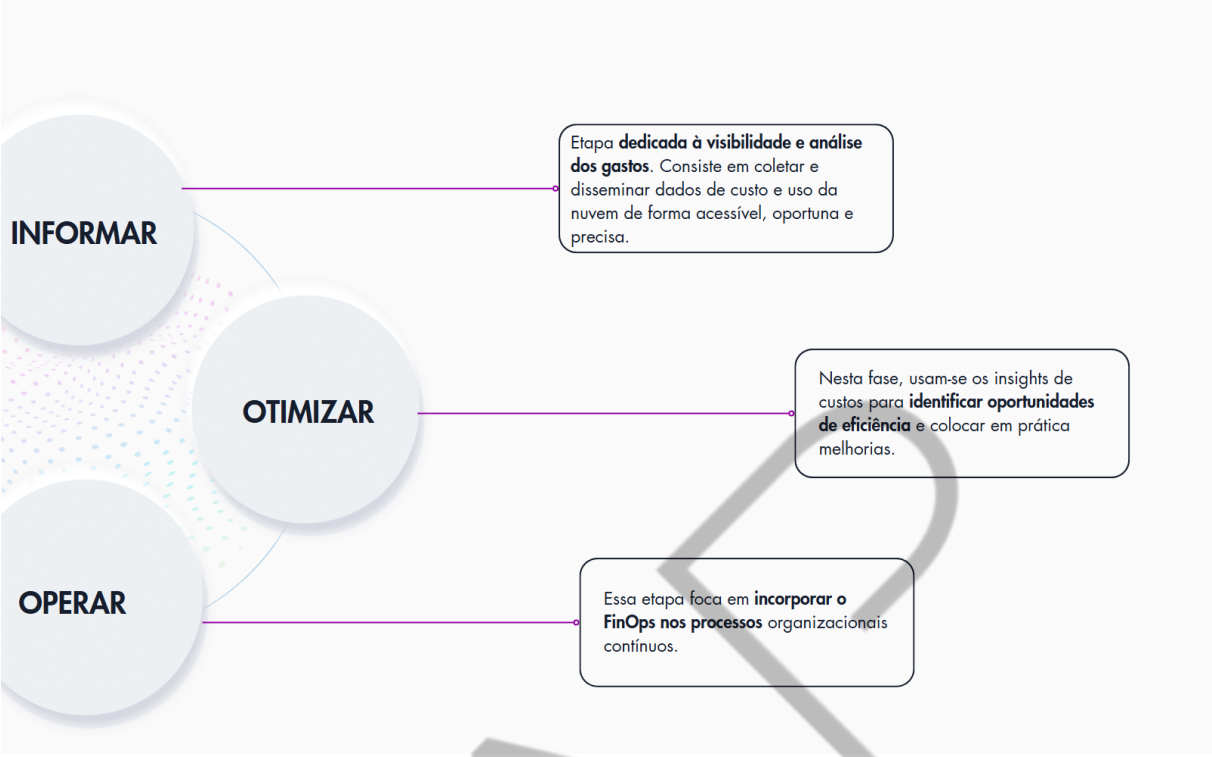


Figura 1 - Ciclo de vida do FinOps ilustrado como um ciclo contínuo com três fases principais – Informar (Visibilidade & Alocação de custos), Otimizar (Taxas & Uso eficiente) e Operar (Melhoria Contínua & Governança Operacional).

Fonte: Elaborado pelo autor utilizando a ferramenta Canva (2026)

Pilares da Engenharia de Dados sob a Ótica Financeira

A eficiência de um pipeline ETL depende do equilíbrio entre quatro pilares fundamentais de engenharia, cada um com seus próprios gatilhos de custo.

A Computação é geralmente o maior motor de custos. Plataformas como o Databricks utilizam motores de execução otimizados (como o Photon) para reduzir o tempo de execução e, consequentemente, o custo total, mesmo com taxas de licenciamento premium. O uso de instâncias baseadas em arquitetura Graviton (ARM) pode oferecer até 24% menos custo para a mesma carga de trabalho.

No Armazenamento, a estratégia de camadas é a chave. Manter dados históricos em discos SSD de alto desempenho pode ser um desperdício. O modelo de tiering permite mover dados raramente acessados para classes como S3 Glacier, reduzindo custos em até 90%. O uso de formatos colunares como Parquet ou Delta Lake também é uma decisão financeira: por serem compactos e permitirem a leitura de colunas específicas (predicate pushdown), eles reduzem o volume de dados

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

escaneados e o custo de consulta em ferramentas como Amazon Athena ou Google BigQuery.

Os custos de Rede e Egress são os "vilões ocultos". Transferir grandes volumes de dados entre diferentes regiões da nuvem ou para a internet pode exceder o custo do processamento em si. Estratégias de FinOps exigem a colocação de recursos (manter processamento e armazenamento na mesma zona de disponibilidade) ou o uso de réplicas locais para evitar taxas de tráfego inter-AZ.

Por fim, a Orquestração garante que clusters efêmeros sejam criados apenas durante o processamento e destruídos imediatamente após, eliminando o custo de ociosidade (idle cost).

FinOps em Tempo Real e Machine Learning

A integração com o Apache Kafka introduz desafios únicos porque os clusters de streaming operam 24/7. Diferente de jobs batch, a ineficiência aqui é faturada a cada segundo. O excesso de partições aumenta a carga de metadados, enquanto políticas de retenção longas multiplicam o custo de armazenamento replicado. Para otimizar, é recomendado alinhar o tempo de retenção às necessidades reais de recuperação e utilizar o suporte a rack awareness para que consumidores leiam de réplicas locais, eliminando taxas de rede.

No campo da Ciência de Dados, o FinOps diferencia o Treinamento (custo finito, similar a CAPEX) da Inferência (custo contínuo, OpEx). Enquanto o treinamento pode ser otimizado com instâncias spot e GPU pooling, a inferência escala com o número de usuários. Se um modelo de IA custar mais por chamada do que a receita que gera, ele é economicamente inviável.

FATOR	IMPACTO	ESTRATÉGIA DE MITIGAÇÃO
Janela de contexto	Tokens de entrada/saída	Limitar tokens e “forçar” respostas concisas
Complexidade do modelo	Hardware de alto custo	Implementar “Model tiering”
Arquitetura de suporte	Busca vetorial e RAG	Otimizar cache semÂntico

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

		e bancos vetoriais

Tabela 1 – Exemplos de fatores de custo na inferência de IA
Fonte: elaborado pelo autor (2026)

Equilíbrio entre Custo e Performance

Um dos principais desafios do FinOps em dados é equilibrar custo e desempenho, avaliando se os ganhos técnicos realmente justificam o aumento de gastos. A proposta do FinOps é tornar esse trade-off explícito nas decisões arquiteturais, buscando a melhor relação custo-benefício. Em vez de maximizar performance a qualquer custo, a abordagem recomendada é otimizar primeiro consultas e modelos de dados, alcançar um desempenho adequado ao negócio e só então investir mais quando o impacto financeiro ou estratégico realmente justificar.

O FinOps mostra que custo e performance não são necessariamente opostos: boas práticas de engenharia podem melhorar ambos simultaneamente. O uso de formatos colunares, compressão e particionamento reduz a quantidade de dados lidos, acelerando consultas e diminuindo significativamente os custos. Da mesma forma, o rightsizing de clusters busca o equilíbrio ideal entre tempo de execução e gasto, evitando tanto recursos insuficientes quanto capacidade ociosa. Com monitoramento e autoscaling, é possível ajustar continuamente a infraestrutura para manter desempenho adequado com o menor custo possível.

FinOps ensina a não aceitar custo desproporcional como “custo de fazer negócio”, quase sempre há algo a otimizar no pipeline para trazer a relação custo/performance a patamares sustentáveis.

Em síntese, custo e desempenho devem ser considerados lados da mesma moeda no desenho de soluções de dados. O objetivo não é nem ser o mais barato nem o mais rápido a qualquer preço, mas maximizar o valor obtido por real gasto. Nas próximas seções, exploraremos práticas concretas onde decisões inteligentes permitem ganhos de eficiência financeira sem comprometer (e às vezes até melhorando) a performance das aplicações de dados.

Métricas de Sucesso e Unit Economics

Para medir a maturidade do FinOps, não basta olhar para o total da fatura. É necessário calcular o Custo Unitário, como o custo por transação ou por modelo

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

treinado. Isso permite que o negócio entenda se o aumento do gasto na nuvem está acompanhando o crescimento da receita.

As fórmulas essenciais incluem:

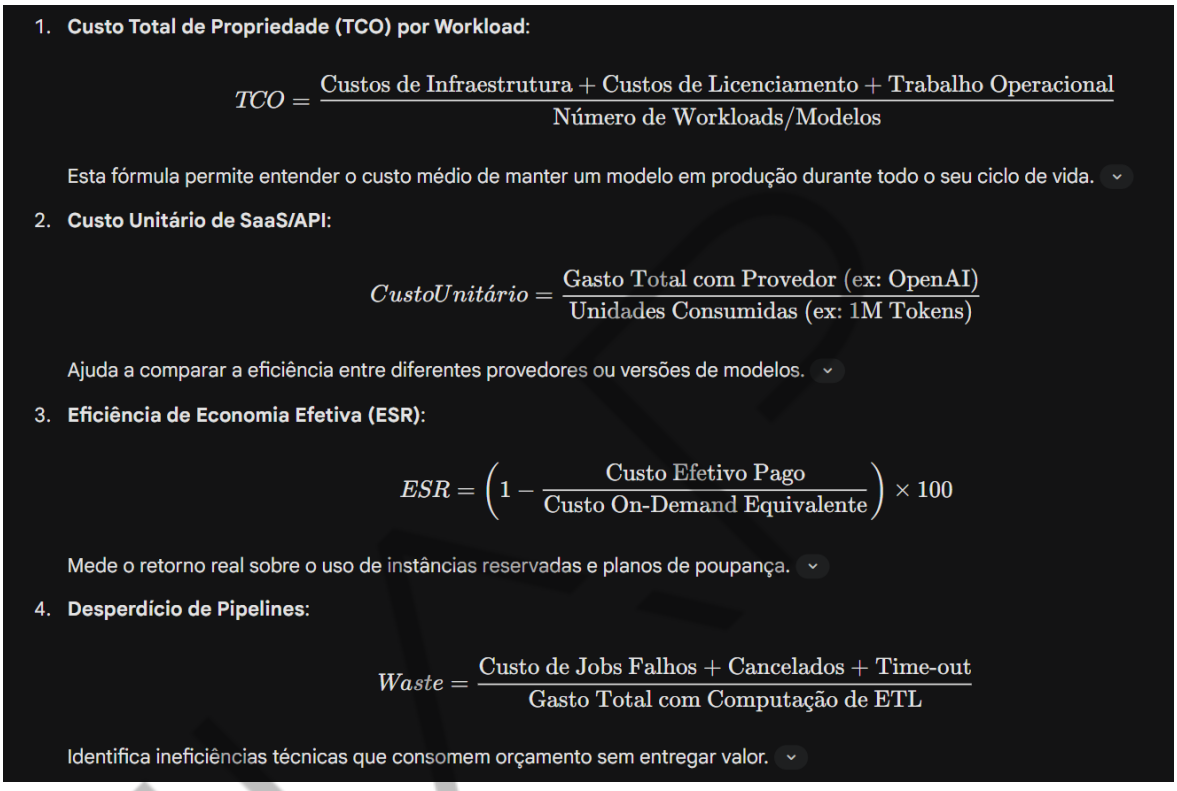


Figura 2 - Fórmula do cálculo TCO e Waste.

Fonte: Adaptado pelo autor a do site FinOps KPIs (2026)

KPIs de Utilização e Performance

Além das métricas financeiras, devemos monitorar a utilização de recursos. Operar abaixo de 40% de eficiência de CPU/Memória é frequentemente considerado um desperdício de capital. Alvos ideais para produção situam-se entre 70% e 80%, equilibrando performance e custo.

KPI	DEFINIÇÃO	ALVO RECOMENDADO
Taxa de Alocação	% do gasto atribuído a etiquetas válidas	> 95% (maturidade run)
Cobertura de desconto	% do gasto coberto por RIs ou Savings Plans	70% - 80% das cargas estáveis

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Acurácia de previsão	Variância entre gastos previsto e real	Dentro de +/- 5% (95% acurácia)
MTTR da Anomalia	Tempo médio para detectar e corrigir picos de custo	< 24 horas para evitar surpresas na fatura

Tabela 2 – Exemplos de KPI para acompanhamento da utilização de recursos.
Fonte: elaborado pelo autor (2026)

Estratégias de Otimização de Custos em Engenharia de Dados

Nesta seção, vamos ver algumas práticas técnicas que possibilitam reduzir custos em ambientes de dados, mantendo ou melhorando a efetividade dos pipelines. Abordaremos otimizações em consultas e modelagem de dados, uso de formatos de armazenamento eficientes, e estratégias de particionamento e ciclo de vida dos dados.

Otimização de *Queries* e Modelagem de Dados

A forma como estruturamos dados e escrevemos consultas SQL (ou código equivalente) tem influência massiva sobre os custos. Consultas não otimizadas podem varrer terabytes desnecessariamente, consumindo mais CPU, memória e I/O, o que, em sistemas de cobrança por uso, significa conta mais alta. Já uma boa modelagem de dados e *queries* bem escritas realizam o mesmo trabalho escaneando menos dados e usando menos ciclos computacionais.

Um princípio fundamental é trazer filtros o mais cedo possível (*predicate pushdown*). Em data warehouses e frameworks tipo Spark, isso significa aplicar cláusulas `WHERE` e projetar colunas (`SELECT` apenas as necessárias) para evitar ler dados que não serão usados. Por exemplo, em vez de `SELECT * FROM vendas` para depois filtrar em aplicativo, faça `SELECT colunas_necessarias FROM vendas WHERE ano = 2023`. Parece óbvio, mas muitos pipelines cometem o erro de extrair conjuntos enormes e filtrar só no final. Sistemas modernos conseguem “empurrar” esses predicados para a leitura dos arquivos, reduzindo o volume lido e processado, economia direta de custo, já que muitos serviços cobram por volume de dados lido. (É preciso, porém, que os dados estejam formatados e particionados de forma compatível, como veremos adiante.)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Na modelagem de dados, um conceito aliado ao FinOps é projetar esquemas que facilitem consultas seletivas. Por exemplo, se sabemos que a maioria das análises de um conjunto de eventos será por data e região, vale particionar ou indexar por essas colunas. Assim, uma consulta filtrando uma região numa data específica acessa só aquela partição, ignorando o resto (economizando tempo e dinheiro). Em data warehouses, é recomendável usar *clustering* ou *partition keys* nas colunas mais filtradas. Outra prática é pré-agregar ou materializar resultados frequentes se isso reduzir ordens de grandeza de processamento para cada consulta futura. Imagine que todo dia dezenas de consultas calculam a média móvel de 30 dias das vendas: em vez de cada query recalcule do zero 30 dias de dados (custo repetido), pode-se criar uma tabela materializada ou sumarizada diariamente. Claro, isso implica custo de armazenamento extra para guardar agregados, mas se bem dimensionado o saldo pode ser positivo, paga-se um pouco de storage para economizar muito compute diário.

Por outro lado, é preciso cuidado: excesso de pré-cálculo ou duplicação pode desperdiçar recursos se as suposições mudarem. FinOps é contra *over-engineering*: materialize ou indexe somente o que traz economia comprovada ou atende necessidades claras, pois cada materialização tem custo de manutenção. Monitorar o *cache hit* ou uso efetivo desses artefatos ajuda a decidir se valem a pena continuar.

Uma query bem otimizada não é só mais rápida, ela consome menos recursos e, na nuvem, menos recursos = menos dinheiro gasto. Como diz um dos princípios do FinOps: *"a eficiência de engenharia agora inclui custo como métrica"*. Adotar essa mentalidade no design de consultas e esquemas é dar um passo largo rumo à excelência FinOps.

Formatos Colunares e Compressão de Dados

A escolha do formato de armazenamento impacta diretamente o custo e a performance do processamento de dados. Formatos colunares como Parquet e ORC, aliados à compressão, reduzem significativamente o volume armazenado e permitem ler apenas as colunas necessárias, gerando economia tanto em storage quanto em consultas. Por isso, tornaram-se o padrão em workloads analíticos, sendo menos

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

indicados apenas em cenários de escrita frequente ou acesso pontual a registros individuais, onde formatos orientados a linha podem ser mais eficientes.

Particionamento de Dados e Ciclo de Vida

O particionamento inteligente é uma técnica essencial para reduzir custos, pois divide grandes conjuntos de dados em segmentos lógicos, permitindo que consultas leiam apenas as partes relevantes por meio de *partition pruning*. Isso evita varreduras completas e diminui significativamente o volume de dados processados. Além disso, o particionamento facilita a gestão do ciclo de vida dos dados, possibilitando mover informações antigas para camadas de armazenamento mais baratas por meio de políticas automáticas, mantendo desempenho adequado para dados recentes e custos controlados para dados frios.

Particionamento também reduz custos indiretos. Por exemplo, melhora *cache hit ratio* em consultas repetidas (já que menos dados a ler aumenta chance de cache), e facilita paralelismo eficiente (vários nós trabalhando em diferentes partições sem competir, evitando gargalos

Um cuidado: as partições devem ser definidas com granularidade certa. Se forem muito amplas (ex.: partição por ano quando consultas são diárias), não ajudam muito; se forem muito finas (ex.: por minuto), viram sobrecarga. FinOps não dita a granularidade, mas observa o padrão de uso: analise logs de consultas e acesso, identifique campos comuns nos filtros e volumes envolvidos, então particione de acordo. E revise periodicamente, se o padrão de acesso mudar, ajuste as partições.

Ações de Infraestrutura Econômica

Indo além das otimizações no nível dos dados e software, existem estratégias de infraestrutura cloud que podem trazer economia significativa sem sacrificar (muito) a qualidade de serviço. Aqui exploraremos algumas abordagens como: uso de instâncias Spot/Preemptible, orquestração de clusters efêmeros, escolhas de serviços gerenciados vs. autogerenciados, e considerações de localidade de dados para reduzir custos. Trata-se de olhar para a base de recursos computacionais com lentes de FinOps e identificar oportunidades para pagar menos pelo mesmo poder de processamento.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Instâncias Spot e Preemptible: são recursos de computação oferecidos pelos provedores a preços bem inferiores (até 90% mais baratos) que o normal, com a contrapartida de serem interruptíveis. A AWS possui as Spot Instances, o Google Cloud tem Preemptible VMs (integradas hoje ao conceito de Spot VMs também), e Azure tem Azure Spot, cada um com suas regras.

É importante, porém, entender as diferenças de comportamento entre provedores: Instâncias Spot/Preemptible variam entre provedores e isso impacta o planejamento. Na AWS e no Azure, elas podem ser encerradas a qualquer momento conforme disponibilidade ou preço, sem limite fixo de duração; já no GCP, as VMs preemptible têm tempo máximo de 24 horas, sendo finalizadas obrigatoriamente após esse período. Por isso, workloads longos ou críticos precisam de tolerância a falhas, como checkpoints e retomada, para aproveitar esses recursos de menor custo sem comprometer a execução.

Clusters Efêmeros e Auto-Desligamento

Uma prática essencial de FinOps é evitar manter a infraestrutura ligada sem uso. Clusters e instâncias devem ser efêmeros, iniciados apenas quando necessários e desligados automaticamente ao final do processamento, usando recursos como auto-terminate, jobs transitórios ou agendamentos. Isso elimina custos de ociosidade, que podem gerar desperdícios significativos quando recursos ficam ativos sem utilização. A combinação de disciplina operacional com automação e alertas de baixa utilização é fundamental para prevenir gastos desnecessários.

Uma extensão desse conceito é usar arquiteturas serverless ou sob demanda quando possível, em vez de manter servidores fixos. Por exemplo, em vez de rodar um servidor ETL continuamente esperando dados, usar AWS Lambda que cobra apenas por execução quando eventos chegam. Ou utilizar serviços gerenciados de data processing como AWS Glue, Google Dataflow, Azure Data Factory, que alocam recursos só durante a execução e depois liberam. Assim, paga-se apenas pelo trabalho realizado. Claro que há *trade-offs* (limites de serviço, tempo de cold start, configurações restritas), mas vale avaliar, especialmente para cargas eventuais ou imprevisíveis. A mensagem fundamental é: desligue ou não provisione recursos antes

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

da hora. FinOps gosta de *ephemerality*, infra que vem e vai conforme a demanda, sem faturas residuais.

Reservas e Planos de Economia

Embora Spots e serverless sejam ótimos para workloads variáveis, muitos sistemas de dados têm uma carga base estável e contínua – por exemplo, um cluster Kafka rodando 24/7, ou um banco de dados analítico que precisa estar sempre disponível. Para esses casos, FinOps recomenda aproveitar os descontos de comprometimento oferecidos: Reserved Instances e Savings Plans (AWS), *Committed Use Discounts* (GCP), *Azure Reservations*, etc. Basicamente, você se compromete a pagar por certa capacidade ou gasto mínimo por 1 ou 3 anos e ganha descontos de 30-60% comparado ao preço sob demanda. Essa estratégia converte OPEX variável em um semi-CAPEX planejado, garantindo economia em workloads previsíveis. Por exemplo, se você sabe que sempre precisará de 3 nós XLarge no cluster ETL, pode reservá-los por 1 ano com desconto. O FinOps aqui envolve planejamento e colaboração com finanças, pois requer aprovação para compromissos de longo prazo.

Localidade e Arquitetura de Rede: como discutido nos custos de transferência, uma ação de infraestrutura é alinhar a topologia para minimizar o tráfego caro. Isso significa, por exemplo, manter sistemas que se comunicam muito dentro da mesma região ou VPC. Se você tem seu data lake no `us-east-1`, procure rodar as VMs de análise também em `us-east-1`, para não pagar egress inter-region. E dentro da região, use endereços privados ou endpoints VPC, se um serviço A chama a API de serviço B via internet pública, muitas vezes a nuvem cobra saída e entrada, enquanto via endpoint privado poderia ser isento ou bem mais barato. FinOps demanda atenção a essas configurações “chatas” de rede, mas que podem fazer diferença em grandes fluxos de dados. Consolidar recursos em menos regiões também ajuda (embora haja casos de multi-região por redundância ou latência, aí equilibra-se necessidade vs. custo).

Um ponto interessante: diferentes clouds têm instâncias especializadas e preços variados para hardware semelhante. Em projetos flexíveis multi-cloud, às vezes pode ser vantajoso rodar um certo workload onde é mais barato, por exemplo, cargas intensivas em GPU poderiam ser treinadas na cloud que oferece GPU mais

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

barata ou descontos melhores, e então os resultados trazidos de volta. Contudo, deve-se tomar cuidado para não gastar mais em transferência entre clouds do que se economizou em compute.

Por fim, considerações de arquitetura distribuída: alguns sistemas permitem segmentar dados e processamento geograficamente para evitar movimentação. Por exemplo, em vez de centralizar um data warehouse global e pagar toneladas de egress consolidando dados de vários países, uma empresa pode optar por manter data warehouses regionais e só agregar resultados sumarizados centralmente (menos volume movimentado). Ou usar um modelo federado onde cada região processa localmente e compartilha apenas pequenos indicadores. Essa engenharia arquitetural é avançada e altamente dependente do caso de uso, mas ilustra como FinOps e arquitetura de sistemas andam juntos, decisões de design podem custar ou economizar milhões a longo prazo.

Comparação de Ecossistemas de Dados em Nuvem

A escolha do provedor de nuvem (AWS, Azure ou GCP) dita as ferramentas de FinOps disponíveis e as estratégias de otimização mais eficazes. Cada nuvem possui uma filosofia arquitetônica distinta que impacta o trabalho do cientista de dados.

Amazon Web Services Flexibilidade e Controle

A AWS oferece o ecossistema mais maduro e configurável, ideal para equipes que possuem expertise técnica profunda e desejam controle total sobre a infraestrutura. O Amazon SageMaker é a plataforma para ML, oferecendo visibilidade granular através do Cost Explorer e Budgets.

- Vantagem FinOps: mercado de instâncias spot altamente líquido e planos de poupança (Savings Plans) extremamente flexíveis que cobrem EC2, Lambda e Fargate.
- Desafio: a vasta gama de opções (mais de 200 serviços) pode levar à complexidade excessiva e dificuldade em manter uma governança centralizada sem automação robusta.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Microsoft Azure Integração Corporativa e IA

O Azure brilha em ambientes corporativos que já utilizam o ecossistema Microsoft. A integração com Active Directory e o uso de ferramentas familiares como Power BI facilitam a adoção de relatórios de FinOps para stakeholders não técnicos.

- Vantagem FinOps: o "Azure Hybrid Benefit" permite reutilizar licenças de software on-premises na nuvem, reduzindo custos de SQL Server e Windows em até 76%.
- Desafio: o provisionamento de recursos pode ser menos ágil que no GCP ou AWS em certos cenários de escalonamento global massivo.

Google Cloud Platform

Simplicidade e Serverless O GCP é construído com uma mentalidade de "serverless-first", abstraindo grande parte da gestão de infraestrutura. O BigQuery é o coração desta estratégia, oferecendo um modelo de custo baseado em dados processados que é ideal para equipes de análise pura.

- Vantagem FinOps: descontos por Uso Sustentado (SUD) são aplicados automaticamente para instâncias que rodam por grande parte do mês, sem necessidade de compromisso prévio. Além disso, a separação total entre armazenamento e computação no BigQuery permite otimizações de custo muito agressivas.
- Desafio: portfólio de serviços menor que o da AWS, o que pode limitar opções para arquiteturas de nicho.

Observabilidade de Custos e Governança Financeira

Implementar FinOps não se resume a técnicas pontuais, requer também mecanismos de governança e monitoramento de custos. Nesta seção, discutiremos a importância de tagueamento de recursos, alocação de custos (*showback/chargeback*), uso de métricas e dashboards de custos, orçamentos e alertas, além da cultura organizacional necessária para sustentar FinOps.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Tagging e Atribuição de Custos

Uma base imprescindível da governança FinOps é conseguir atribuir cada gasto de nuvem a um responsável, projeto ou unidade de negócio. Para isso, usamos *tags* (etiquetas) ou separação por contas/projetos. Cada recurso na nuvem (VM, bucket, banco de dados, etc.) deve receber metadados indicando, por exemplo: Projeto = *Marketing-CampanhaX*, Ambiente = *Dev*, Time = *DataScience*, Dono = *Fulano*. Assim, quando a conta chegar, é possível fatiar: “quanto custou a campanha X? E o ambiente Dev vs Prod? E qual time gerou mais despesas?”. Sem tags, a fatura da nuvem é uma caixa-preta por serviço, difícil dizer qual iniciativa consumiu o quê. Com tags, ganha-se visibilidade granular e promove-se a responsabilização descentralizada, os times tomam posse de seus gastos, pois sabem que estarão identificados.

Na prática, muitas empresas adotam showback ou chargeback para dar visibilidade dos custos de nuvem por time, incentivando comportamento mais responsável e decisões orientadas a valor. Ferramentas nativas dos provedores e soluções especializadas permitem detalhar gastos por tags, projetos e ambientes. A recomendação de FinOps é padronizar tags mínimas (projeto, equipe, ambiente, centro de custo) e, em ciência de dados, incluir identificadores de experimentos ou modelos, conectando diretamente custo e inovação e permitindo avaliar se o investimento técnico realmente compensou os resultados obtidos.

Showback vs. Chargeback

São modelos de alocação. No *showback*, você mostra para os times quanto eles gastaram, mas o pagamento sai de um orçamento central, é mais educativo, para visibilidade. Já no *chargeback*, cada departamento tem seu próprio orçamento e literalmente “paga” (internamente) por seu uso de nuvem. O FinOps inicial geralmente começa com showback, pois ainda está fomentando cultura. Com maturidade, algumas organizações adotam chargeback parcial ou total, inserindo custos de cloud nas unidades de negócio. Isso cria incentivos financeiros diretos: por exemplo, o departamento A pode decidir não rodar certa análise caríssima porque gastaria todo seu budget, se realmente quiser, precisa justificar o valor ou otimizar. Independentemente do modelo, o importante é mensurar e divulgar os custos de

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

maneira compreensível. As métricas devem ser levadas às equipes de engenharia regularmente, assim como se acompanha performance ou qualidade. Em dashboards internos, pode haver um gráfico “custo por 1000 usuários atendidos” ou “gasto por pipeline executada”, indicadores de eficiência que orientam decisões.

Orçamentos e Alertas

Uma prática preventiva de FinOps é configurar limites de orçamento e alarmes de custo. Todos os provedores oferecem isso: define-se um valor mensal ou diário esperado, e se o gasto real o atingir (ou projetar atingi-lo), um alerta é enviado (email, SMS, Slack etc.). Isso pode ser refinado por serviço, por tag, por projeto.\ Por exemplo, “alertar se gastos do projeto *DataScience-Experimentação* excederem R$10k no mês”. Esses alarmes não bloqueiam (a não ser que você programe algo), mas funcionam como um sinal de fumaça para anomalias. Se um job entrar em loop infinito lendo dados e gastando sem parar, o alerta vai disparar muito antes da fatura fechar, dando chance de intervenção.

Além de alertas de limite absoluto, existem ferramentas de detecção de anomalias de gasto usando ML (ex.: AWS *Cost Anomaly Detection*, Azure *Cost Alerts*, ou terceiros). Elas aprendem seu padrão de consumo e avisam se algo fora do comum acontece (ex.: “custo do serviço X está 50% maior do que o usual nesta altura do mês”). É uma camada extra de proteção, útil especialmente em ambientes complexos com muitos serviços.

Cultura e Processo: por fim, nenhuma ferramenta substitui a cultura e processos organizacionais. FinOps prospera em culturas onde há colaboração multifuncional, times de engenharia, produto e finanças trabalhando juntos continuamente, e onde valor de negócio guia decisões técnicas. Para inculcar isso, algumas ações são úteis:

- **Treinamento e conscientização:** capacitar engenheiros de dados a entender a fatura da cloud, a usar as ferramentas de custo, a pensar em otimização. Workshops internos de boas práticas FinOps, etc.
- **Políticas e *guardrails* oficiais:** por exemplo, padronizar que todo projeto novo deve estimar seu custo esperado e ter *tags* adequadas; ou estabelecer que nenhum recurso caro fica em Dev/projeto pessoal sem aprovação após

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

X dias. FinOps não visa engessar a inovação, mas algumas regras claras evitam deslizes (similar a políticas de segurança).

- **Revisões periódicas de custo:** incluir discussões de custo em *sprints* e post-mortems. Se um pipeline foi caro demais no mês, analisar o porquê e planejar ajuste. Tratar picos de gasto como incidentes de produção, entender causa raiz (e.g., “consulta ineficiente escrita pelo time X”), ação corretiva (“refatorar consulta ou aumentar partições”) e ação preventiva (“adicionar alerta ou documentação para evitar repetição”).
- **Objetivos compartilhados:** definir metas de eficiência, como “reduzir custo por pipeline em 15% neste trimestre” ou “manter gastos de cloud estáveis enquanto volume de dados cresce 20%”, isso tende a engajar os times a buscar ativamente oportunidades FinOps.

Quando todos na organização se sentem responsáveis pelo uso consciente, atinge o nível do FinOps esperado: não é mais alguém “policiando” custos de fora, e sim as próprias equipes otimizando porque entendem que isso libera recursos para inovação e garante sustentabilidade. Esse é o cenário ideal em que FinOps deixa de ser um projeto à parte e vira parte da operação diária, tão importante quanto monitorar uptime ou qualidade dos dados.

Para ajudar organizações a avaliar seu nível de maturidade em FinOps, pode-se usar checklists de autoavaliação.

FinOps é uma responsabilidade multidisciplinar

O sucesso da implementação de FinOps depende da colaboração diária entre os times. Embora as responsabilidades técnicas sejam distintas, os objetivos financeiros são compartilhados.

STAKEHOLDER	RESPONSABILIDADES DE EXEMPLOS	EXEMPLO
Finanças	Previsão de gastos, relatórios e orçamento	Alocação de custos por projeto/modelo (chargeback interno)
Liderança/Executivos	Definir metas e suportar iniciativas FinOps	Priorizar investimentos em dados com base no ROI esperado

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

Engenheiros de Dados	Otimização técnica da infraestrutura	Uso de instâncias Spot em jobs ETL; automação de desligamento
Cientistas de Dados	Experimentação sustentável com custo em mente	Taguear recursos de treino de modelos para monitorar gastos

Tabela 3 – Responsabilidade dos times com base em FinOps.
Fonte: elaborado pelo autor (2026)

Conclusão

O avanço das práticas de FinOps no contexto de dados em nuvem representa não apenas uma tendência, mas uma necessidade estratégica para empresas que buscam escalar suas operações de forma sustentável. Ao integrar governança financeira diretamente aos pipelines de dados e modelos de Machine Learning, torna-se possível transformar decisões técnicas em ações alinhadas ao valor de negócio, promovendo maior eficiência e controle de gastos.

Ferramentas emergentes, como as plataformas FinOps-as-a-Service e os mecanismos de tagueamento automatizado por inteligência artificial, demonstram que a evolução tecnológica está a serviço da maturidade operacional. Essas soluções elevam o nível de visibilidade sobre os custos e permitem que times multidisciplinares, engenheiros, cientistas de dados e analistas financeiros, colaborem com base em métricas concretas e atualizadas em tempo real.

Mais do que uma disciplina técnica, o FinOps estabelece uma nova cultura organizacional, como exemplificado pela abordagem DevFinOps. Ao envolver o time financeiro desde a concepção arquitetural, rompe-se a separação entre orçamento e infraestrutura, criando um ambiente onde custo, performance e inovação caminham juntos. Essa transformação cultural é o alicerce para que organizações tomem decisões sustentáveis, transparentes e orientadas a valor.

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

MERCADO, CASES E TENDÊNCIAS

A integração do FinOps ao MLOps tem ganhado destaque à medida que ferramentas de governança de custos passam a ser incorporadas nativamente a pipelines de Machine Learning e plataformas como MLflow e Vertex AI, permitindo maior controle e previsibilidade financeira durante o ciclo de vida dos modelos.

Paralelamente, observa-se o avanço do uso de inteligência artificial para automatizar o processo de etiquetagem de custos, aplicando tags por dataset, pipeline ou modelo, o que reduz a dependência de processos manuais e aumenta a granularidade da visibilidade financeira. Outro movimento importante no mercado é o crescimento de plataformas FinOps-as-a-Service, como CloudZero, Zesty e nOps, que oferecem análises preditivas de gastos com base no comportamento de uso de dados e recursos.

Complementando esse cenário, surge a cultura DevFinOps, que propõe a inclusão do time financeiro já nas fases iniciais de desenho técnico das arquiteturas, promovendo uma colaboração mais próxima entre engenharia, dados e finanças, e conectando diretamente as decisões técnicas ao impacto orçamentário.

“FinOps Fridays – Cloud Cost Optimization” - Podcast: Designing Cloud Cost Visibility for Data Teams

Este episódio aborda como a visibilidade de custos impacta decisões em times de dados, desde a escolha de ferramentas até o gerenciamento de ambientes de machine learning.

https://open.spotify.com/show/0Mjr4VlDXQbuHU0Lltys6L

“Cloud FinOps: Collaborative, Real-Time Cloud Financial Management” – J. R. Wilde, M. Broude, M. Fuller: este livro é considerado a principal referência técnica e estratégica sobre práticas FinOps. A segunda edição traz casos atualizados, frameworks de governança e estratégias específicas para workloads de dados e machine learning.

“FinOps Foundation” – Tendências e Boas Práticas - A principal referência global para a evolução do FinOps: Disponivel em: https://www.finops.org

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

O QUE VOCÊ VIU NESTA AULA?

Começamos definindo FinOps e entendendo seus pilares (Informar, Otimizar, Operar) aplicados ao ciclo de vida dos dados. Passamos pelos fundamentos de onde surgem os custos em arquiteturas de dados e enfatizamos a necessidade de equilíbrio entre gasto e desempenho. Em seguida, detalhamos uma série de técnicas concretas, da otimização de queries ao uso de instâncias Spot, demonstrando que decisões técnicas inteligentes podem simultaneamente melhorar performance e reduzir despesas.

Integrar FinOps em um ambiente de dados significa adotar um modelo mental no qual cada ação técnica tem visibilidade de seu impacto econômico. Isso não quer dizer colocar dinheiro acima de tudo, quer dizer alinhar as decisões tecnológicas aos objetivos de negócio, assegurando que cada real investido em nuvem traga retorno tangível em valor de dados. À medida que a disciplina de FinOps evoluiu, ficou claro que não é só um “braço de finanças tentando cortar custos”, mas sim uma função interdisciplinar. Sucesso em FinOps vem quando engenharia, produto e financeiro trabalham juntos com dados compartilhados e metas comuns. Por exemplo, definem métricas de unidade (como custo por modelo treinado com sucesso) e se guiam por elas para melhorar continuamente.

Por fim, reforçamos que FinOps não é “pão-durismo tecnológico”. Pelo contrário, trata-se de gastar para acelerar negócios, mas gastando de forma inteligente. Às vezes, o FinOps mostrará que vale a pena investir mais em certo aspecto para colher retorno muito maior, por exemplo, pagar por uma ferramenta de monitoramento de custo que evita desperdícios grandes, ou expandir um pipeline que traz receita direta. A diferença está em ter os dados e critérios para fazer essas escolhas conscientemente, e não às cegas.

Mapa Mental

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

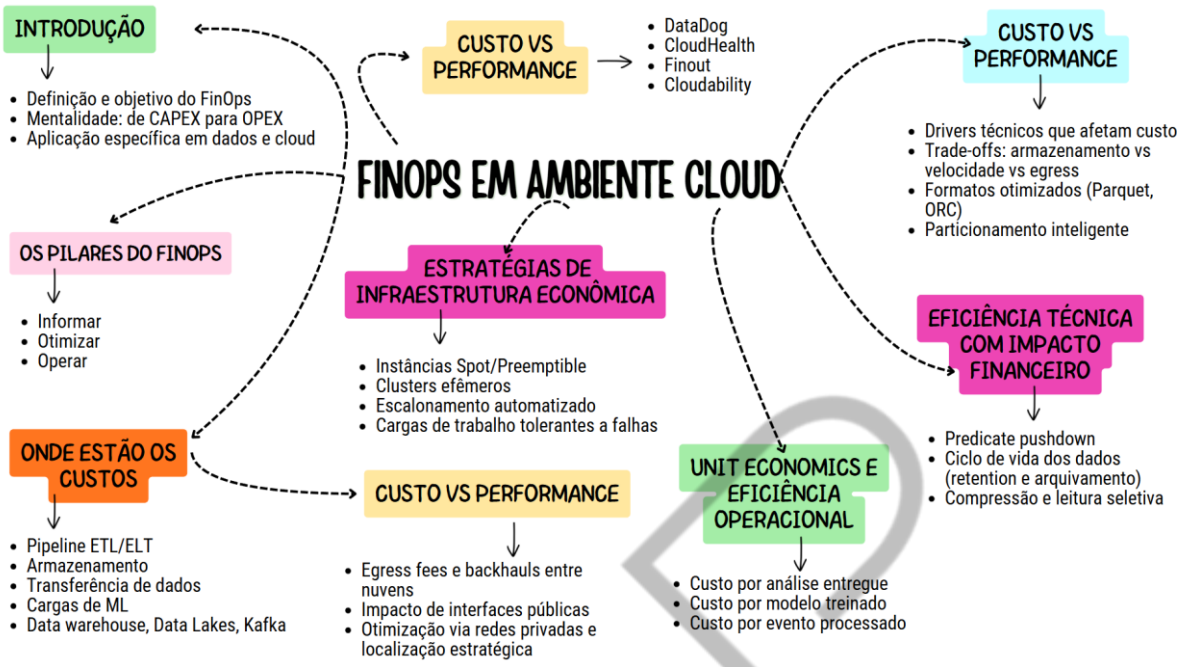


Figura 2 - Mapa mental com o conteúdo abordado
Fonte: Elaborado pelo autor utilizando a ferramenta Canva IA (2026)

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

REFERÊNCIAS

AMAZON WEB SERVICES. *AWS Cost Optimization*. AWS Well-Architected Framework, 2023. Disponível em: https://docs.aws.amazon.com/wellarchitected/latest/cost-optimization-pillar/. Acesso em: 25 mar. 2026.

AZURE. *Monitoramento e controle de custos na Azure*. Microsoft Learn, 2023. Disponível em: https://learn.microsoft.com/pt-br/azure/cost-management-billing/. Acesso em: 25 mar. 2026.

DOIT INTERNATIONAL. *Essential FinOps KPIs to Optimize Cloud Spend*. [S. l.], 2023. Disponível em: https://www.doit.com/blog/finops-kpis/. Acesso em: 25 mar. 2026.

FINOPS FOUNDATION. *FinOps Assessment Working Group*. [S. l.], 2023. Disponível em: https://www.finops.org/wg/finops-assessment/. Acesso em: 25 mar. 2026.

MICROSOFT. *FinOps Framework*. Microsoft Learn, 2023. Disponível em: https://learn.microsoft.com/pt-br/cloud-computing/finops/framework/finops-framework. Acesso em: 25 mar. 2026.

PELANOR. *Learn Essential FinOps KPIs*. Pelanor Learning Center, 2023. Disponível em: https://www.pelanor.io/learning-center/learn-essential-finops-kpis. Acesso em: 25 mar. 2026.

WILDE, J. R.; BROUD, M.; FULLER, M. *Cloud FinOps – Tomada de decisões colaborativas em tempo real sobre o valor da nuvem*. 2. ed. Rio de Janeiro: Alta Books, 2024.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com

PALAVRAS-CHAVE

FinOps. MLOps. Governança Financeira.

FIAP

PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com



PDF exclusivo para Cleivin Lauermann - rm376917
cleivin.lauermann@gmail.com